# 1 | 기본 개념

3부를 시작하면서, 산업공학에서 다루는 다양한 분석기법들은 크게 시스템이 안고 있는 문제의 해답을 찾는 모형(generative model)과 시스템이 어느 상태에 있는지를 평가하는 모형(evaluative model)으로 나눌 수 있다고 하였다. 앞 장의 경제성 분석기법들은 주로 평가 모형에 속하는 것들이다. 여러 개의 대안이 있을 때, 어느 것이 다른 것에 비해 얼마나 더 좋은지 또는 나쁜지를 경제성의 기준에서 비교하고 선택하는 일에 초점을 맞춘 것이다. 그에 반해, 이 장에서 살펴볼 수리적 분석기법들은 문제의 답을 찾는 것들이다. 시스템의 목적이 설정되고 시스템이 움직일 수 있는 조건이 주어진 상황에서, 시스템에 가장 적합한 답을 찾는 일에 초점을 맞춘다. 또한 문제의 내용도 수리적 상징(mathematical symbol)으로 표현되고, 문제의 답을 찾는 과정도 수리적 작업(mathematical manipulation)을 활용하기 때문에 '수리적 분석'이라는 이름이 붙여졌다.

수리적 분석의 개념을 이해하기 위해 우선 하나의 예제를 생각해 보자. 어느 기업에서 A와 B의 두 가지 상품을 생산한다고 하자. 상품 A는 개당 2원의 이익이 나고, B는 개당 5원의 이익이 발생한다. 상품 A를 생산하는 데 9개의 재료를 투입하고 3시간 동안 기계를 사용해야 하며, B는 5개의 재료와 4시간의 기계를 사용해야 한다. 이때 재료는 최대 300개까지 사용할 수 있으며, 기계 가동 시간은 최대 200시간이라고 한다. 또 상품 A는 최소 5개 이상을 생산해야만 한다고 한다. 이 상황에서, 이익을 극대화할 수 있는 상품 A와 B의 생산량을 결정하는 것이 주어진 과제이다.

이 과제를 수리적 모형으로 생각해 보자. 우선 제품 A의 생산량을 $X_1$, 제품 B의 생산량을 $X_2$라는 두 개의 변수(variable)로 설정한다. 또 두 개의 변수를 선형(linear)으로 결합하면 $aX_1 + bX_2$와 같은 하나의 함수(function)가 만들어진다. 이 예제의 총이익은 $2X_1 + 5X_2$라는 함수가 되며 이것을 극대화(maximize)로 표현하면 바로 목적함수(objective function)가 된다. 또 사용할 수 있는 자원의 양을 함수로 표현하면 이것들이 곧 제약조건(constraint)이 된다. 마지막으로 목적함수와 제약조건을 바탕으로 최적의 해(optimal solution)를 찾는 과정이 알고리즘(algorithm)이다.

이제 수리적 접근을 시스템과 모델의 관계로 정리해보자. 그림 8-1에 도시되어 있는 것처럼, 시스템이 하나의 문제를 안고 있다고 하자. 시스템은 크고 복잡하기 때문에 문제를 쉽게 표현하기 어렵다. 여기서 문제의 핵심요소를 변수로 설정하고 변수들 간의 결합으로 함수를 구성하자. 그러면 크고 복잡한 시스템을 작고 단순한 모델로 바꿀 수 있다. 시스템의 문제가 목적함수와 제약조건으로 구성되는 모델의 문제로 바뀌게 된 것이다. 이제 알고리즘을 이용하여 목적함수의 해를 찾았다고 하자. 그러면 모델로부터 얻은 해를 우리가 궁극적으로 찾으려고 하는 시스템의 해로 대체하게 된다. 이 과정에서 변수, 함수, 알고리즘 모두가 수리적 표현과 수리적 작업으로 이루어지기 때문에 '수리적' 분석이라고 하는 것이다.

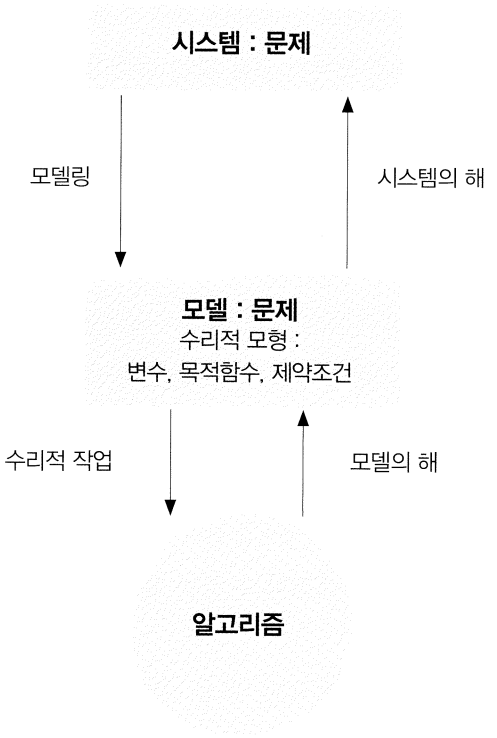



그림 8-1 수리적 분석에서 시스템과 모델의 관계

# 2 | 수리계획법

## 1. 기본 개념

수리적 분석에서 사용될 수 있는 최적화 기법은 매우 다양하다. 아주 고전적인 기법은 주어진 함수인 $f(x)$를 미분한 다음, 미분한 함수인 1차 도함수 $f'(x)=0$의 근(root)을 구하여 최적해를 찾는 방법이다. 이 방법의 원리는 매우 단순하다. 만일 최적화 문제의 목적이 최댓값(최솟값)을 찾는 것이라면 현재 위치에서 함숫값이 증가(감소)하는 방향으로 계속 옮겨가야 한다. 이 과정을 반복하다가 더 이상 올라갈(내려갈) 곳이 없는 평평한 점에 다다르면 그 점이 곧 최댓값(최솟값)이 된다. 이때 1차 도함수 $f'(x)$가 증가(감소)의 기울기를 뜻하므로 $f'(x)=0$이 되면 더 이상 올라갈(내려갈) 방향이 없는 최적의 해를 찾았다는 뜻이 된다. 오래 전의 수학자들이 함숫값의 최대화(최소화) 문제를 풀기 위해 만들었던 이 기법은 지금도 중·고등학교 수학에서 다루고 있으며 실무현장에서도 널리 사용되고 있다. 하지만 이 기법은 아무런 제약조건이 없는(unconstrained) 상황에서 함수 자체의 최대화(최소화) 문제만을 다룬다는 한계를 안고 있다.

수리계획법(mathematical programming)은 현대 산업공학에서 가장 오래되고 또 가장 자주 사용되는 대표적인 최적화 기법이다. 이 기법은 가용한 자원이 한정되어 있다는 조건(constraint)하에서, 수익의 극대화나 비용의 최소화와 같은 경영상의 목적(objective)을 달성하는 문제의 해(optimal solution)를 찾는 의사결정 기법이다. 즉, 목적이 되는 함수뿐 아니라 그 함수를 둘러싼 제약조건들이 추가로 주어지는 문제를 다루는 것이다. 앞 절에서 본 예제가 전형적인 수리계획법의 예가 된다.

수리계획법은 제2차 세계대전을 전후한 1950년대 이후부터 비약적으로 발전한 분야이다. 우리는 1장에서 산업공학의 발전에 OR(Operations Research) 또는 MS(Management Science)라는 분야가 지대한 공헌을 하였다는 사실을 설명한 적이 있다. 이 분야의 뿌리가 되는 것이 바로 수리계획법이다. 이 방법론은, 오늘날 크고 복잡한 의사결정 문제를 모형화(modeling)하고 그 해답을 찾는 과정에 가장 폭넓게 활용되는 유용한 기법으로 자리 잡고 있다.

넓은 의미의 수리계획법은 다시 몇 가지의 구체적인 기법으로 나눌 수 있다. 가장 대표적

인 모형은 선형계획법(Linear Programming : LP)이다. 선형계획법은 말 그대로 수익(비용)의 발생이나 자원의 사용이 선형(linear)의 비율로 변한다고 가정하는 모형이다. 예를 들어, 제품을 1단위 팔아서 100원의 수익이 있으면 2단위를 팔면 200원, 10단위를 팔면 1,000원 하는 식으로 늘어난다고 가정한다. 자원의 사용도, 제품 1단위 만드는 데 10톤이 들었다면 2단위 만드는 데 20톤, 10단위 만드는 데 100톤이 든다는 식으로 가정한다. 또한 모형의 해(solution)가 정수뿐 아니라 실수의 값을 가질 수도 있다고 가정한다.

만일 늘어나고 줄어드는 비율이 선형의 비율이 아니라 비선형의 비율이라고 가정하면, 분석 모형도 선형계획법이 아니라 비선형계획법(Non-Linear Programming : Non-LP)이 된다. 또 제품의 생산 단위가 100.5단위와 같은 소수점으로 표현될 수 없고 반드시 100단위와 같이 정수(integer)로 정해져야 한다면, 정수계획법(Integer Programming : IP)이 된다. 실제의 경영 프로젝트를 생각해 보면, 비선형계획법이나 정수계획법이 더 현실적인 가정이라고 할 수 있다. 그러나 문제를 푸는 과정이나 방법에 있어 선형계획법이 훨씬 쉽고 효율적이기 때문에, 특별한 문제가 없는 한 선형계획법이 가장 폭넓게 사용되고 있다. 따라서 여기서도 선형계획법만을 다루기로 한다.

선형계획법을 비롯한 수리계획법은 다양한 실무현장에서 폭넓게 사용되고 있다. 예를 들어, 항공회사의 경우 항공 일정(schedule)을 수립하는 문제, 항공 노선과 구간에 대해 항공기를 할당(assignment)하는 문제, 예약시스템의 설계와 공항 운영관리 시스템의 개선 문제 등이 대표적인 사례가 될 수 있다. 제조기업에서는 생산계획(production plan)을 수립하는 문제, 제품(부품)의 생산량과 생산시점을 결정하는 문제, 재료비 및 인건비를 절감하는 문제 등을 다룰 수 있다. 유통회사의 경우라면 전국의 유통망을 설계하고 유통창고의 입지(location)를 선정하는 문제, 배송인력의 일정을 관리하는 문제 등을 들 수 있다. 기업 현장의 실무적인 주제 외에도 최근에 각광을 받고 있는 인공지능(AI)과 기계학습(machine learning)에서 많이 다루는 분류문제(classification) 등도 내용을 들여다보면 최적화(optimization) 기법과 밀접하게 연결되어 있다는 것을 알 수 있다.

## 2. 선형계획법

### 기본 모형

선형계획법의 기본 모형은 결정변수(decision variable), 목적함수(objective function), 제약조건(constraints)이라는 세 개의 핵심요소로 이루어진다.

선형계획법의 첫 단계는 결정변수(decision variable)들을 선정하는 것이다. 만일 여러 제품의 생산을 다루는 문제라면, 제품 하나하나의 생산량이 결정변수($x_i$)가 된다. 다음은 각각의 결정변수들의 수익이나 비용을 나타내는 일차식인 목적함수(objective function)를 제시하는 작업이 이루어진다. 개별제품의 단위당 수익이나 비용을 $c_i$라고 한다면 목적함수는 $Z = c_1x_1 + c_2x_2 + \cdots + c_nx_n$이 된다. 목적함수는 문제의 성격에 따라, 수익의 경우라면 최대화(maximization) 문제가 되고, 비용의 경우라면 최소화(minimization) 문제가 된다.

다음 단계는 자원에 관한 제약조건(constraint)을 설정하는 일이다. 여기서 자원은 원자재, 부품, 자본, 인력, 시간, 거리, 공장의 생산능력 등 실제 상황에 따라 다양하게 나타날 수 있다. 자원의 사용량과 가용량은 일반적으로 일차 부등식의 형태로 표현되며, 이 일차 부등식을 제약조건이라고 한다. 먼저 사용량을 보자. 어떤 자원에 대해 개별제품의 생산량과 단위당 사용량(a)을 곱하면, 그 자원에 대한 그 제품의 총사용량이 결정된다. 모든 제품의 총사용량을 더하면 그 자원 전체의 사용량이 계산된다. 다음으로 사용량과 가용량(b)의 관계를 보자. 모든 자원은 가용량이 제한되어 있고, 또한 사용량의 합은 가용량을 넘을 수 없다. 따라서 제약조건은 부등식의 형태로 표현된다. 또 결정변수의 값은 0과 같거나(생산을 안 할 경우) 0보다 커야(실제로 생산을 할 경우) 한다. 따라서 결정변수의 값이 음이 될 수 없다는 제약조건을 나타내는 비음조건(non-negativity condition)도 필요하다.

결정변수, 목적함수, 제약조건으로 구성된 일반적인 선형계획 모형의 가장 정규적인 형태는 다음과 같다.

$$
\begin{aligned}
max\ z = \ & c_1x_1 + c_2x_2 + \cdots + c_nx_n \\
s.t. \quad & a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n \le b_1 \\
& a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n \le b_2 \\
& a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_m \le b_m \\
& x_i \ge 0 \ (i = 1, 2, \cdots, n)
\end{aligned}
$$

목적함수에서 max는 최대화(maximization)라는 뜻이다. 만약 문제가 최소화 문제라면 목적함수에서 최대화(max) 대신 최소화(min)를 쓰고, 이때에는 제약조건의 부등호 방향이 반대가 된다. *s.t.*라는 기호는 'subject to'를 줄인 말로 제약조건을 의미한다.

## 심플렉스 알고리즘

### (1) 기본 원리

심플렉스 알고리즘(simplex algorithm)은 선형계획법 모형의 최적해(optimal solution)를 찾는 데 사용되는 대표적 알고리즘이다. 우리말로는 단체법이라고 불린다. 이 알고리즘은 1947년에 단치히(Dantzig)에 의해 처음으로 개발되었으며, 그 후 여러 학자들에 의해 더욱 발전되어 왔다. 심플렉스 알고리즘의 기본적인 내용과 절차를 간략히 알아보도록 하자.

심플렉스 알고리즘의 기본 아이디어는 수리적 접근보다는 기하학적 접근으로 설명하는 것이 더 쉽고 간편하다. 다음의 간단한 예를 생각해 보자. $X_1$과 $X_2$의 두 제품을 생산하는 시스템의 설계 문제에서, 목적함수는 이익을 극대화하는 최적 생산량 $X_1^*$과 $X_2^*$를 찾는 데 있다. 자원의 가용량에 관한 제약조건이 세 개 있으며, $X_1$과 $X_2$ 모두 0보다 크거나 같아야 한다는 조건, 즉 비음조건도 있다. 위의 수리적 모형을 기하학적인 형태로 도시한 것이 그림 8-2이다.

이 그림에서 빗금 친 영역의 경계선들이 제약조건을 의미한다. 각각의 제약조건이 각각의 경계선을 뜻하는 것이다. 따라서 목적함수를 만족시키는 최적의 해는 제약조건을 만족시키는 빗금 친 영역, 즉 가능영역(feasible region) 안에 존재해야 한다. 문제는 이 영역 안에는 무수

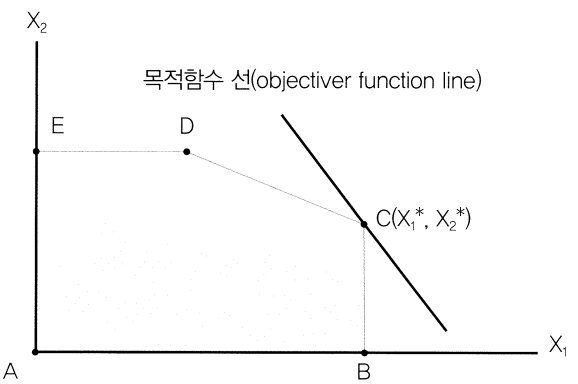



그림 8-2 수리계획 문제의 기하학적 도형

히 많은 점들이 있기 때문에 모든 점들을 일일이 비교할 수는 없다는 데 있다. 이 책의 범위를 넘어서는 얘기지만, 선형 모형의 경우 경계선들의 접점으로 만들어지는 꼭짓점의 수는 유한(finite)하며, 또 최적의 해는 반드시 꼭짓점 중에 하나가 되어야 한다는 사실이 수학적으로 증명되어 있다. 그렇게 되면 위 그림의 경우 A, B, C, D, E의 다섯 개 꼭짓점의 목적함수 값만 비교하면 최적의 해를 찾을 수 있게 된다. 또 꼭짓점 가운데 최적의 해는, 목적함수의 선(line)과 접점을 이루는 C 점이 된다는 사실도 수리적으로 증명되어 있다.

위의 간단한 예에서는 다섯 개의 꼭짓점만 고려하면 되지만 결정변수와 제약조건이 수백 개가 넘는 현실적 문제의 경우라면 어떻게 되는가? 꼭짓점의 수가 유한하다고 하지만 실제로 수십만 개가 넘는 꼭짓점이 있는 경우, 이들 모두를 하나하나 비교한다는 것은 거의 불가능하다. 심플렉스 알고리즘은 다음과 같은 원리로 이를 해결한다.

심플렉스 알고리즘은 어떤 꼭짓점이 최적의 해인지 아닌지를 판정하기 위해, 바로 인접하고 있는 점들과 목적함수의 값을 비교하는 작업을 반복하는 절차로 이루어져 있다. 제일 먼저 어느 한 꼭짓점에서 출발한다고 치자. 그 주위에는 여러 개의 꼭짓점들이 인접해 있다. 그러면 그 점과 인접하고 있는 다른 꼭짓점들과 목적함수의 값을 비교한다. 인접한 점들 가운데 만일 그 점보다 더 좋은 목적함수 값을 갖는 점이 하나라도 있으면, 그 점은 최적의 해가 아니다. 따라서 다음 꼭짓점으로 이동해야 한다. 그러나 만일 더 좋은 값을 갖는 점이 주위에 하나도 없으면, 그 점이 바로 최적의 해가 된다. 그렇게 되면, 나머지 점들은 더 이상 알아볼 필요 없이 알고리즘을 끝내면 된다. 예를 들어, 꼭짓점의 수가 30만 개인 경우에 최적의 해를 100번의 반복(iteration) 끝에 찾았다면 나머지 29만 9,900개의 꼭짓점은 더 이상 생각할 필요가 없는 것이다. 따라서 매우 큰 문제도 아주 짧은 시간 안에 해를 구할 수 있는 경우가 대부분이다.

### (2) 알고리즘

수리적인 관점에서 심플렉스 알고리즘을 구체적으로 설명하는 일은 이 책의 범위를 벗어난다. 특히, 꼭짓점에서 꼭짓점으로 이동하면서 변수와 계수가 바뀌는 과정을 수리적으로 이해하려면 선형대수(linear algebra)에 나오는 행간연산(row operation)에 대한 지식이 필요하다. 따라서 여기에서는 전반적인 절차의 기본적 아이디어만을 간략하게 설명하기로 한다. 심플렉스 알고리즘은 크게 다음의 5단계로 구성된다.

### 1단계 : 표준 모형 만들기

심플렉스 알고리즘의 첫 번째 단계에서는 부등식(inequality)으로 이루어진 원래의 모형을 등식(equality)의 모형으로 바꾸는 일을 하게 된다. 이 작업을 해야 하는 이유는 해(solution)를 구하기 위해서는 문제가 반드시 등식의 형태로 주어져야 하기 때문이다. 흔히 선형 연립방정식(system of linear equations)이라고 부르는 아래의 식들이 만족하는 해를 찾는 것이다. 이때 아래와 같이 등식으로 이루어진 선형계획 모형을 표준형(standard form)이라고 한다.

$$
\begin{aligned}
&a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\
&a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\
&\cdots \\
&a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n = b_m
\end{aligned}
$$

예를 들어, 다음과 같은 원래의 선형계획 모형이 있다고 하자.

$$
\begin{aligned}
max\ Z &= 50X_1 + 80X_2 \\
s.t. \quad & 5X_1 + 6X_2 \le 180 \\
& 2X_1 + 4X_2 \le 80 \\
& 8X_1 + 6X_2 \le 250 \\
& X_1, X_2 \ge 0
\end{aligned}
$$

이제 이 모형을 표준모형으로 바꾸기 위해서는 각각의 제약조건에 대해 가상 변수(dummy variable)를 하나씩 집어넣어 부등식을 등식으로 변환하게 된다. 이 변수들을 여유 변수(slack variable)라고 부르기도 한다. 위에서 제약조건이 $5X_1 + 6X_2 \le 180$으로 되어 있는 부등식은 가상의 변수 $X_3$를 도입하여 $5X_1 + 6X_2 + X_3 = 180$의 등식으로 만들 수 있다.

여기서는 제약조건이 3개이므로 모두 3개의 가상변수(여유변수) $X_3$, $X_4$, $X_5$가 필요하다. 이 가상변수들을 원래의 모형에 집어넣으면 아래와 같이 연립방정식들로 이루어진 표준형이 만들어진다. 이 가상변수들은 단지 제약조건의 부등식을 등식으로 바꾸기 위해 도입한 것들이므로 목적함수($Z$)에 아무런 영향을 미치지 않는 것에 주의하자.

$$
\begin{aligned}
max\ Z &= 50X_1 + 80X_2 \\
s.t. \quad & 5X_1 + 6X_2 + X_3 = 180 \\
& 2X_1 + 4X_2 + X_4 = 80 \\
& 8X_1 + 6X_2 + X_5 = 250 \\
& X_1, X_2 \geq 0
\end{aligned}
$$

### 2단계 : 초기 가능해 구하기

표준형이 만들어진다고 해서 바로 해(solution)를 구할 수 있는 것은 아니다. 위의 예제를 보면, 5개의 변수($X_1$, $X_2$, $X_3$, $X_4$, $X_5$)와 3개의 등식으로 이루어지는 연립방정식이 주어져 있다. 이때 연립방정식을 풀어 답을 얻기 위해서는 변수의 수와 등식의 수가 같아야만 한다. 하지만 일반적인 선형계획법 문제에서는 변수의 수($n$)가 제약식의 수($m$)보다 많기 때문에($n > m$) 기존의 방법으로는 답을 찾을 수 없는 문제가 발생한다. 그렇다면 어떻게 이 문제를 해결할 수 있을까? 해결책은 원래 주어진 n개의 변수 중 제약식의 수와 같은 m개만 남겨두고 나머지 ($n-m$)개의 변수는 아예 0으로 값을 정해버리는 것이다. 그렇게 되면 값을 구해야 하는 변수의 수와 연립방정식으로 주어지는 제약식의 수가 모두 $m$개로 같아지게 된다. 이때, 처음부터 값이 0으로 설정되는 변수를 비기저 변수(nonbasic variable)라고 하고 0 이외의 값을 갖게 되는 변수를 기저 변수(basic variables)라고 한다.

이제 위에서 설명한 방법을 토대로, 알고리즘을 시작할 출발점이 되는 첫 번째 꼭짓점을 정하게 된다. 기하학적으로 꼭짓점이라고 부르는 점들을 수리적으로 표현하면 가능해(feasible solution)가 된다. 가능해는 말 그대로 연립방정식의 해가 될 수 있는 기본요건인 제약조건과 비음조건을 만족하는 해를 말한다. 따라서 가능해는 여러 개 얻을 수 있다. 이 가운데 주어진 알고리즘의 출발점이 되는 가능해를 선정하게 되는데 이 가능해를 초기해(initial solution)라고 한다.

위의 예로 다시 돌아가서, 다섯 개의 변수 가운데 처음부터 $X_1 = 0, X_2 = 0$으로 하고 시작해보자. 그러면 남아있는 변수의 수와 제약식의 수가 각각 3개로 같아지게 된다. 이 경우에 나머지 변수들은 자연스럽게 $X_3 = 180, X_4 = 80, X_5 = 250$과 같이 0이 아닌 해(solution)를 갖게 되면서 하나의 초기해가 만들어질 수 있다. 이때, 0의 값을 갖는 $X_1$과 $X_2$는 비기저 변수가 되고 0 이외의 값을 갖는 나머지 $X_3$, $X_4$, $X_5$는 기저 변수가 된다. 기하학적으로 보면, 이 초기해는 $X_1 = 0, X_2 = 0$이므로 원점에 해당되는 꼭짓점이 된다.

### 3단계 : 최적해의 판정

일단 초기해를 구하면 다음 단계는 그 해가 최적해(optimal solution)인가를 판정하는 작업을 하게 된다. 최적해의 판정은 목적함수에 나타난 계수들의 부호를 보고 한다(뒤에서 다시 설명하겠지만, 해가 바뀌면서 행간연산의 결과로 목적함수의 계수들도 바뀌게 된다). 만일 모든 결정변수들의 계수가 음수(negative)이면 그 해가 곧 최적해가 된다. 그 이유는 간단하다. 모든 계수가 음수라면, 만일 해가 바뀌어서 다른 꼭짓점으로 이동하여 결정변수의 값이 하나라도 바뀌면(커지면) 목적함수의 값이 늘어나기는커녕 오히려 줄어들기 때문이다. 즉, 해를 바꾸지 않는 것이 최선이 되기 때문에 그 점이 곧 최적해가 되는 것이다.

좀 더 쉽게 설명하기 위해 위의 예를 다시 보자. 여기서 목적함수는 $Z = 50X_1 + 80X_2$이다. 그리고 초기해는 $X_1 = 0, X_2 = 0$이다. 따라서 목적함수 $Z$의 값은 0이 된다. 이것이 최적해일까? 아니다. 왜냐하면 목적함수의 계수들이 양수(positive)이기 때문이다. 계수가 양수이면 만일 $X_1$이나 $X_2$의 값이 0이 아니라 다른 값으로 바뀌면서(즉, $X > 0$으로 커지면서) 해가 달라지면 목적함수의 값도 증가하게 된다. 목적함수를 최대화하는 것이 목표이므로 당연히 다른 해로 옮겨가야 한다. 반대로 계수들이 모두 음수라면, 해가 바뀌면서 목적함수의 값이 오히려 감소하므로 다른 해로 옮겨가면 안 된다. 즉, 그 해가 바로 최적해가 되는 것이다.

### 4단계 : 탈락변수 및 진입변수의 선택

만일 초기 가능해가 최적해가 아니라면 다음의 가능해(꼭짓점)로 옮겨가야 한다. 이 작업은 현재 $X = 0$인 변수 가운데 하나를 $X > 0$으로 만들고, 반대로 현재 $X > 0$인 변수 가운데 하나를 $X = 0$으로 만드는 일로 이루어진다. 현재 $X = 0$이지만 $X > 0$으로 바꿀 수 있는 후보는 $X_1$과 $X_2$이다. 여기서 어떤 변수를 바꿀지는 계수들의 비율을 비교하여 결정하게 된다. 즉, 비율이 높을수록 그 변수가 한 단위 늘어날 때마다 목적함수가 커지는 효과가 크기 때문에 비율이 가장 높은 변수를 선택하는 것이다. 위의 예에서는 목적함수가 $50X_1 + 80X_2$이므로 $X_1$이 한 단위 늘어나면 목적함수는 50만큼, $X_2$가 한 단위 늘어나면 목적함수는 80만큼 증가한다. 따라서 $X_2$를 늘리는 것이 더 바람직하다. 이때, $X = 0$에서 $X > 0$으로 들어오는 변수를 진입변수(entering variable)라고 하고, 반대로 $X > 0$에서 $X = 0$으로 나가는 변수를 탈락변수(leaving variable)라고 한다.

이 기준과 절차에 의해 새로운 가능해를 찾는 작업이 바로 행간연산(row operation)이다. 위의 연립방정식은 여러 개의 방정식들을 행렬(matrix)의 모양으로 모아 놓은 것이다. 이때 행(row)의 순서를 바꾸어도 해는 변하지 않는다. 또한 각 방정식의 좌변과 우변에 어떤 수를 곱

할 수도 있고, 어떤 수를 곱한 방정식을 다른 방정식에 더해도 연립방정식은 성립이 된다. 따라서 이러한 연산을 통해 새로운 해를 찾을 수 있다(자세한 과정은 생략). 여기서 다시 한 번 주의할 점은 가능해의 변화에 따라 목적함수와 제약조건의 계수도 달라지고 목적함수의 값도 변한다는 사실이다.

- 5단계 : 새로운 가능해의 최적해 판정

새로운 가능해를 찾으면, 앞의 3단계에서 설명한 기준에 따라 새로운 가능해가 최적해인지 아닌지를 판정하게 된다. 만일 최적해를 찾았으면 알고리즘은 종료된다. 그렇지 않으면 앞의 4단계 과정으로 돌아가서 알고리즘을 계속한다.

물론 실제의 문제를 위에서와 같이 일일이 손으로 풀 수는 없다. 변수의 수가 10개만 되어도 문제의 크기는 엄청나게 증가한다. 따라서 현실에서는 선형계획법 소프트웨어를 사용하게 된다. 그림 8-3에서 보듯이, 엑셀을 포함한 다양한 소프트웨어가 나와 있기 때문에 문제의 규모와 성격에 맞는 것을 선택하여 사용하면 된다. 따라서 전문가가 아닌 경우라면, 문제의 답을 구하는 방법보다 문제의 목적을 제대로 이해하고 문제의 내용을 제대로 설계하는 것이 훨씬 중요하다.

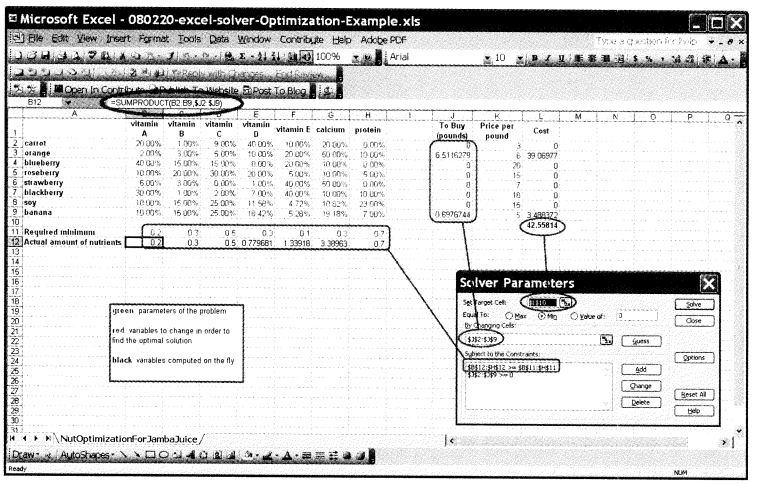



그림 8-3 엑셀을 이용한 선형계획법 활용 예시

- 6단계 : 민감도 분석

최적의 해를 구한 이후에는 추가적으로 민감도 분석(sensitivity analysis)을 수행한다. 이 작업은 알고리즘이 끝난 후에 이루어지기 때문에 사후분석(post-optimality analysis)이라고 부르

기도 한다. 민감도 분석은 원래 주어진 문제에서 만일 중요한 요인의 값이 바뀐다면(what-if), 그 변화가 원래 문제의 결과에 어떤 영향을 미칠 것인지를 알아보는 작업이다. 즉, 최적의 답을 찾는 것에서 끝나지 않고 만일 현재의 조건과 상황이 달라지면 어떤 변화가 일어날지도 함께 알아보는 것이다.

민감도 분석을 통해 의사결정자가 얻을 수 있는 정보에는 어떤 것들이 있을까? 다시 말해, 민감도 분석의 주요 주제들은 무엇이 있을까? 다양한 주제들이 있지만, 대표적인 질문들로는 다음 몇 가지를 들 수 있다. 앞의 예제를 이용하여 각 주제의 의미를 알아보자. 첫째, 목적함수의 계수가 바뀌면 최적해에 어떠한 영향을 미치는지가 사후분석의 주제가 된다. 각 제품의 단위당 이익이 달라지면 당연히 최적의 생산량도 바뀔 수 있기 때문이다. 둘째, 제약식에서 오른쪽(우변)에 있는 자원의 가용량이 달라지면 최적해에 어떤 변화가 나타나는지도 주제가 된다. 실제로 자원의 가용량은 늘어나거나 반대로 줄어들 수도 있고, 그 변화는 알고리즘의 결과에도 영향을 미칠 수 있는 것이다. 셋째, 제약식에서 변수의 계수 즉 단위당 자원의 사용량이 달라지면 최적해에 어떠한 영향을 미치는지도 관심사가 된다. 넷째, 새로운 제약식이 추가되거나 기존의 제약식이 제거되는 변화에 최적해는 어떠한 영향을 받는지도 분석의 주제로 들 수 있다. 마지막으로, 새로운 변수의 추가가 최적해에 미치는 영향을 알아보기도 한다.

### 예제

앞에서 살펴본 예제를 좀 더 확장시킨 다음의 예를 생각해 보자. 우선 제품의 종류는 A, B, C, D의 네 가지이다. 따라서 각 제품의 생산량인 변수도 $X_1$, $X_2$, $X_3$, $X_4$의 네 개가 된다. 상품 A는 개당 60원, B는 개당 80원, C는 개당 100원, D는 개당 120원의 이익이 발생한다. 이번에는 사용하는 자원도 세 가지로 많아졌고, 최대로 쓸 수 있는 각 자원의 가용량은 각각 200, 24, 100으로 주어져 있다. 각 제품의 생산에 들어가는 각 자원의 사용량은 제약조건에 나타나 있다. 이 상황에서, 이익을 극대화할 수 있는 A, B, C, D의 생산량을 결정하는 것이 주어진 과제이다.

선형계획 문제의 수리적 모델은 다음과 같이 수립된다.

$$60x_1 + 80x_2 + 100x_3 + 120x_4$$
$$10x_1 + 10x_2 + 20x_3 + 20x_4 \leq 200$$

$$
\begin{aligned}
max\ z = \ & 6x_1 + 2x_2 + 4x_3 + 2x_4 \le 24 \\
s.t. \quad & 10x_1 + 14x_2 + 2x_3 + 4x_4 \le 100 \\
& x_i \ge 0\ (i = 1, 2, 3, 4)
\end{aligned}
$$

### 1단계

먼저 위의 원형을 아래와 같은 표준형으로 바꾼다. 그러기 위해서는 $x_5$, $x_6$, $x_7$의 3개의 가상변수를 도입하게 된다.

$$
\begin{aligned}
max\ Z = \ & 60X_1 + 80X_2 + 100X_3 + 120X_4 \\
s.t. \quad & 10X_1 + 10X_2 + 20X_3 + 20X_4 + X_5 = 200 \\
& 6X_1 + 2X_2 + 4X_3 + 2X_4 + X_6 = 24 \\
& 10X_1 + 14X_2 + 2X_3 + 4X_4 + X_7 = 100 \\
& X_1, X_2, X_3, X_4 \ge 0
\end{aligned}
$$

### 2단계

이제 초기해를 출발점으로 하여 심플렉스 알고리즘을 시작한다. 초기의 가능해는 원점인 $x_1 = 0,\ x_2 = 0, x_3 = 0, x_5 = 200, x_6 = 24, x_7 = 100$으로 한다. 이때 목적함수 $Z = 60X_1 + 80X_2 + 100X_3 + 120X_4$의 값은 $x_1 = 0,\ x_2 = 0, x_3 = 0, x_4 = 0$이므로 0이 된다.

### 3단계

초기해가 최적해인지를 판정한다. 목적함수의 계수가 모두 양수이므로 초기해는 최적해가 아니다.

### 4단계

다른 가능해를 찾는다. 여기서 진입변수가 될 수 있는 후보는 $x_1 = 0,\ x_2 = 0, x_3 = 0, x_4 = 0$이다. 그 가운데 계수가 120으로 가장 큰 $x_4$를 진입변수로 선택한다. 그러면 $x_4$가 양의 값으로 바뀌면서 행간연산의 결과로 $x_5 = 200, x_6 = 24, x_7 = 100$ 가운데 하나는 0이 되어 탈락변수가 된다. 알고리즘의 기준을 따라 새로운 가능해를 찾는다(자세한 과정은 생략). 그 결과, 새로운 가능해는 $x_1 = 0,\ x_2 = 0, x_3 = 0, x_4 = 10$으로 바뀐다. 또한 목적함수 $Z = 60X_1 + 80X_2 + 100X_3 + 120X_4$의 값은 1,200이 된다.

### 5단계

바뀐 해가 최적해인지를 판정한다. 위의 행간연산에 의해 목적함수의 계수들이 바뀐다는 사실을 기억하자. 여기서 자세한 계수의 값을 보여 주지는 않지만, 바뀐 해의 목적함수에는 아직 계수의 부호가 양수인 변수가 있는 것을 확인할 수 있다. 그러므로 바뀐 해는 최적해가 아니다. 따라서 4단계로 돌아간다.

### 6단계

다른 가능해를 찾는다. 이번에는 계수 값이 가장 큰 $x_2$가 진입변수가 된다. 역시 행간연산의 결과로 새로운 가능해는 $x_1 = 0,\ x_2 = 0, x_3 = 0, x_4 = 8$로 바뀐다. 이때 목적함수 $Z$의 값은 $x_1 = 0$, $x_2 = 4, x_3 = 0, x_4 = 8$이므로 1,280이 된다.

### 7단계

바뀐 해가 최적해인지를 판정한다. 역시 행간연산에 의해 목적함수의 계수가 달라진다. 이번에는 목적함수의 모든 계수의 부호가 음수인 것을 확인할 수 있다. 즉, 현재의 가능해가 곧 우리가 찾는 최적해인 것이다. 따라서 알고리즘을 종료한다. 이때 각 제품의 생산량은 A = 0개, B = 4개, C = 0개, D = 8개이며, 목적함수의 최댓값은 1,280이다.

# 1 | 기본 개념

바로 앞 장에서 시스템 문제의 답을 찾는 수리적 분석에 대해 알아보았다. 이번 장의 통계적 분석은 다시 시스템의 상태를 평가하는 모형으로 돌아간다. 그런 의미에서, 통계적 분석기법은 그 이전의 경제성 분석기법과 비슷한 성격을 지닌다고 할 수 있다. 다른 점은 실증적인 데이터를 기반으로 확률과 통계의 이론을 활용한다는 것이다.

산업경영공학에서 확률과 통계 지식을 많이 활용하는 이유는 무엇일까? 2장에서 시스템의 개념을 설명할 때, 시스템은 움직이는 패턴의 임의성 정도에 따라 확정적 시스템(deterministic system)과 확률적 시스템(probabilistic system)으로 나눌 수 있다고 하였다. 확정적 시스템은 말 그대로 확실히 예측할 수 있는 방식으로 작동하는 시스템이다. 예를 들어 생산량 $Y$와 투입량 $X$의 관계가 $Y = 2X$라면, $X$가 10일 경우 Y는 항상 20이 되는 시스템을 가리킨다. 따라서 수리적 분석이 가능하고 최적의 해(solution)를 찾기도 수월하다. 반면에 확률적 시스템은 어느 정도 규칙에 따라 움직이기는 하지만 항상 예측의 오류가 발생하는 시스템이다. $Y = 2X$에서 $X$가 10일 경우, $Y$는 0.5의 확률로 15가 되기도 하고 0.5의 확률로 25가 될 수도 있는 것이다. 이런 시스템에서는 구성요소의 상호관계를 확률적으로만 설명할 수 있어 불확실성이 항상 존재한다. 현실세계에서 만나는 대부분의 시스템은 확률적 시스템이고, 확률적 시스템을 분석할 때는 확률적 모형과 통계적 기법을 사용할 수밖에 없다.

통계적 분석의 개념을 이해하기 위해, 먼저 하나의 예제를 생각해 보자. 어느 제약회사에서 신약 개발에 필요한 정보를 얻기 위해 지난 10년간 종합병원을 찾은 환자들의 의료기록을 확보하였다. 하지만 이 기록을 모두 사용하기에는 규모가 너무 방대하여 그중에서 $n$개의 자료만을 추출하여 분석하기로 하였다. 여기서 모든 환자의 자료가 모집단(population)이고 $n$개의 자료가 표본(sample)이다. 이제 표본 안에 있는 환자 개개인을 관찰치(observation)로 하여 $O_1$부터 $O_n$까지 일련번호를 붙여놓자. 다음으로 환자 각각에 대해 연령($X_1$), 체중($X_2$), 혈압($X_3$), 소득수준($X_4$), 소금섭취량($X_5$)을 조사하였다. 이러한 정보를 정리한 데이터베이스의 기본 구조가 표 9-1에 정리되어 있다.

이 데이터베이스를 데이터 행렬(data matrix)이라고 부르고, 행렬 모양의 일정한 표준 형식

표 9-1 통계분석 데이터베이스의 기본 구조

| | $X_1$ | $X_2$ | $X_3$ | $X_4$ | $X_5$ |
|---|---|---|---|---|---|
| $O_1$ | $X_{11}$ | $X_{21}$ | $X_{31}$ | $X_{41}$ | $X_{51}$ |
| $O_2$ | $X_{12}$ | $X_{22}$ | $X_{32}$ | $X_{42}$ | $X_{52}$ |
| . | | | | | |
| . | | | | | |
| $O_n$ | $X_{1n}$ | $X_{2n}$ | $X_{3n}$ | $X_{4n}$ | $X_{5n}$ |

에 맞추어 가지런히 정리되어 있는 정보를 '정형(structured) 데이터'라고 한다. 정형 데이터는 바로 통계작업에 쓸 수 있다. 사칙연산을 할 수도 있고, 공식에 집어넣어 답을 구할 수도 있고, 방정식의 해를 찾을 수도 있기 때문이다. 하지만 그렇게 구조화되지 않은 데이터는 '비정형(unstructured) 데이터'가 된다. 오늘날의 빅데이터(big data)는 텍스트(text) 정보, 그림 및 사진 정보와 같이 행렬 모양으로 표현할 수 없는 비정형 정보를 많이 포함하고 있다. 이러한 비정형 데이터는 먼저 일정한 형식에 맞도록 바꾸어 주는 과정을 거쳐야 통계작업에 사용할 수 있다.

여기서 환자의 상태를 보여 주는 연령, 체중 등의 속성 하나하나가 변수($X$)가 된다. 각 변수에 대해 모집단이 갖는 값이 모수(parameter)이고, 표본이 갖는 값이 통계량(statistics)이다. 흔히 모수는 $\theta$로, 통계량은 $\hat{\theta}$로 표기한다. 예를 들어, 혈압이라는 변수에 대해 모집단 전체의 평균 혈압은 모평균이라는 모수가 되고 표본의 평균 혈압은 표본평균이라는 통계량이 된다. 모집단 전체를 조사하지 않는 한 모수값을 알 수는 없다. 하지만 표본의 통계량은 쉽게 얻을 수 있다.

이제 그림 9-1을 보자. 이 그림은 통계적 접근을 모집단과 표본의 관계로 정리한 것이다.

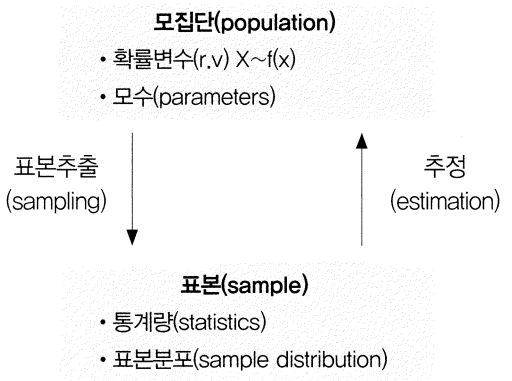



그림 9-1 통계적 분석에서 모집단과 표본의 관계

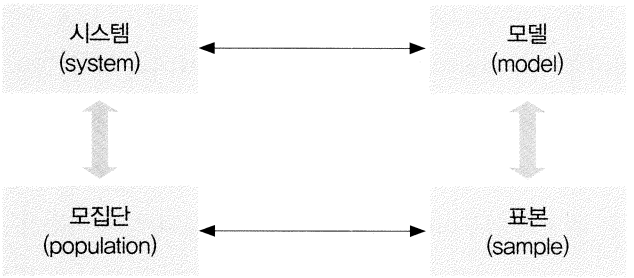



그림 9-2 시스템-모델과 모집단-표본의 관계

모집단의 모수값을 알고자 하는 것이 우리에게 주어진 과제이다. 문제는 모집단은 크고 복잡하기 때문에 모수값을 측정할 수 없다는 데 있다. 따라서 해결책으로 작고 단순한 표본을 추출한다. 이제 표본에서 어떤 변수의 통계량, 예를 들어 표본의 평균과 분산을 구해보자. 이것이 통계량이다. 표본으로부터 얻은 통계량을 우리가 궁극적으로 찾으려고 하는 모집단의 모수값으로 대체한다. 이것을 추정(estimation)이라고 부른다. 표본평균인 $\bar{X}$로 모평균인 $\mu$를 추정하고, 표본분산인 $s^2$로 모분산인 $\sigma^2$을 추정하는 것이 대표적인 예이다.

요약하면, 통계적 분석은 모집단의 일부인 표본으로부터 얻은 통계량 값을 바탕으로 모집단의 모수값을 추정하는 작업을 의미한다. 그림 9-2에서 보듯이, 산업공학에서 말하는 시스템과 모델의 관계를 통계적 분석에 대입하면, 시스템에 해당되는 것이 모집단이고 모델에 대응되는 것이 표본이다.

그렇다면 통계적 분석은 어디에서 어디까지 할 수 있을까? 원칙적으로 말하면, 위의 데이터베이스를 가지고 하는 모든 작업은 통계적 분석이 된다. 따라서 통계적 분석의 범위는 매우

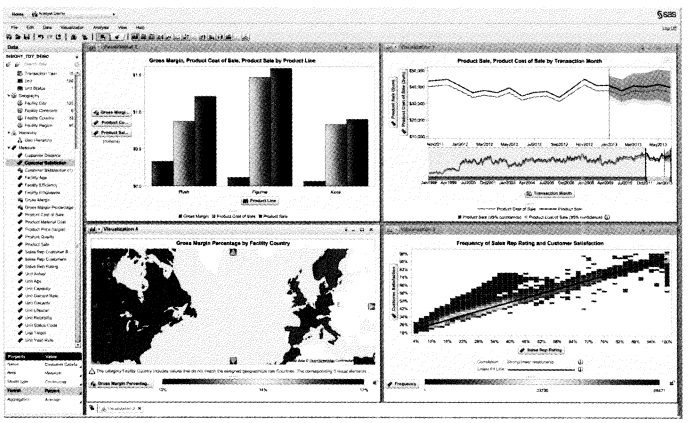


그림 9-3 SAS를 이용한 통계분석 결과의 시각화

방대하고 사용되는 기법도 아주 다양하다. 그 많은 내용을 여기에 담을 수는 없고 산업공학에 자주 쓰이는 대표적인 분석주제와 기법 몇 가지만을 알아보기로 한다. 우선은 각 변수의 통계량을 가지고 모수값을 추측하는 추정(estimation)이 있다. 관심을 넓혀, 변수와 변수 사이의 관계를 알아보는 작업으로는 상관분석(correlation analysis)이나 회귀분석(regression analysis)을 들 수 있다. 이것도 물론 추정의 일부이다. 또 전체의 관찰치를 속성이 비슷한 소그룹으로 나누는 군집분석(cluster analysis)을 할 수도 있다. 어느 기법을 사용하든 분석의 결과는 수치로 나타낼 수도 있고 그림으로 나타낼 수도 있다. 특히, 그림 9-3에서 보듯이, 통계패키지를 사용하면 시각화된 다양한 형태를 보여 줄 수 있다.

## 2 | 확률과 통계

통계적 분석을 위해서는 확률이론에 대한 기본적인 이해가 필요하다. 역사적으로도, 확률론의 응용으로 만들어진 학문이 통계학이다. 사실 자연과학에서 발전해 온 확률이론이 통계학이라는 응용학문으로 연결된 것은 19세기 이후의 일이다. 결국 확률론이 통계학의 뿌리인 셈이다.

먼저 확률이론의 기본 개념을 알아보자. 우리가 경영활동에서 발생하고 관찰하는 현상을 통계의 용어로 표현하면 '하나의 사건(event)이 발생했다'고 한다. 사건 하나하나는 서술적으로 표현된다. 예를 들어, '주사위를 던졌는데, 3이 나왔다'하는 식이다. 따라서 수리적 분석을 위해서는 먼저 사건의 내용을 수치로 정량화해야 한다. 이러한 목적으로, 각각의 사건을 실수(real number)의 값으로 바꾼 것이 변수(variable)이다. 이 변수의 값이 그때그때 다르게 나오기 때문에 확률변수(random variable)라고 말한다. 매번 다른 값이 나오기는 하지만 어떤 규칙 안에서, 즉 주어진 범위 안에서 패턴을 보이며 나오게 될 때 이 패턴을 정형화시킨 것이 확률분포(probability distribution)이다.

그렇다면 왜 통계적 분석은 확률에 대한 지식을 필요로 할까? 앞에서 언급한대로, 통계적 분석의 핵심은 추정에 있다. 표본의 통계량을 가지고 모집단의 모수값을 알아내려고 하는 것

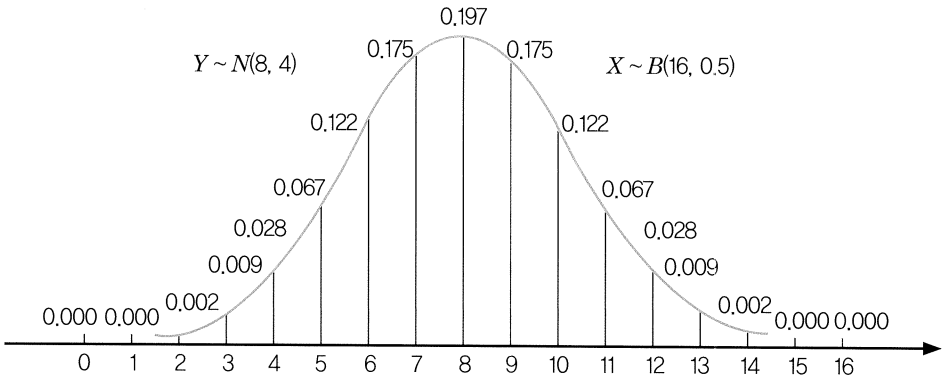



그림 9-4 이항분포를 정규분포로 근사시키는 과정

이다. 당연한 얘기지만, 추정을 하려면 변수의 값이 일정한 패턴을 가지고 나온다는 가정이 있어야 한다. 그렇지 않으면 추정 자체가 무의미하거나 불가능하다. 이 패턴에 대한 가정이 바로 확률분포이고 확률분포의 유형과 속성에 관한 지식을 모아놓은 것이 확률론이다. 그러므로 확률에 대한 이해가 있어야 통계적 추정을 할 수 있는 것이다.

확률분포는 크게 이산(discrete)분포와 연속(continuous)분포로 나눌 수 있다. 만일 변수들이 정숫값을 가진다면 이산적 분포를 따르는 것이고 실숫값을 가진다면 연속적 분포를 따르는 것이다. 이산분포의 대표로는 이항분포(binomial distribution)를 들 수 있다. 쉽게 설명하면, 성공과 실패로 나뉘는 실험을 여러 번 했을 때 성공의 횟수를 변수로 하는 것이 이항분포이다. 당연히 변수는 이산적 값을 갖게 되고 따라서 이항분포는 이산분포이다. 연속분포의 대표는 정규분포(Normal distribution)이다. 정규분포에서 변수들은 모든 실숫값을 가질 수 있다.

실제로 두 분포는 밀접한 관련을 맺고 있다. 그림 9-4에 도시되어 있는 것처럼, 이항분포(변수 $X$)를 갖는 통계적 실험을 계속 반복하면 정규분포(변수 $Y$)에 가까워진다. 막대들을 붙여놓은 히스토그램(histogram) 모양이 종모양의 곡선(bell-shaped curve)으로 바뀌는 것이다. 이를 근사(approximation)라고 한다. 실제로 거의 모든 이산분포는 실험이 반복되면서, 즉 표본의 수가 커지면서 대표적인 연속분포인 정규분포에 가까워진다.

그러면 왜 통계적 분석에서는 이산분포를 연속분포로 전환시키려고 할까? 말을 바꾸어, 왜 이산분포보다 연속분포를 선호할까? 그것은 확률계산의 용이성 때문이다. 이산분포의 경우에는 사건 하나하나마다 발생의 확률을 계산해야 한다. 하지만 연속분포의 경우에는 적분을 통해 쉽게 계산할 수 있다. 더구나 정규분포의 경우에는 표준화된 표(table)가 잘 만들어져 있어 확률의 계산이 아주 쉽다.

이제 통계적 분석에서 자주 사용되는 몇 가지의 중요한 확률분포에 대해 알아보자. 세상에는 수많은 패턴의 통계적 사건들이 일어나는 만큼 다양한 확률분포들이 존재한다. 먼저 이항분포에서 출발해 보자. 앞에서 이미 설명한대로, 이항분포는 한마디로 성공과 실패의 횟수를 변수로 한다. 성공과 실패의 두 가지 경우만 일어나는 사건에서, 성공의 확률을 $p$라고 하면 실패의 확률은 당연히 $1-p$가 된다. $n$번의 실험을 했을 때, 성공의 평균 횟수는 $np$이고 평균 분산은 $np(1-p)$가 된다. 또 다른 이산분포인 포아송분포(Poisson distribution)는 이항분포와 아주 가까운 분포이다. 이항분포에서 실험의 횟수인 $n$이 크고 성공의 확률인 $p$가 아주 작은 경우에 포아송분포를 따르기 때문이다.

이제 연속분포인 지수분포(exponential distribution)를 알아보자. 지수분포는 포아송분포와 불가분의 관계를 맺고 있다. 두 분포가 같은 모수인 $\mu$를 공유하기 때문이다. 하지만 두 분포의 모수는 서로 역수(inverse)의 값을 갖는다. 포아송분포의 모평균이 $\mu$라면 지수분포의 모평균은 $1/\mu$이 되는 것이다. 마지막으로 정규분포(normal distribution)는 모든 분포의 근사점이 되는 분포이다. 각각의 변수가 서로 다른 분포를 따른다고 해도 실험을 계속 반복하면, 즉 표본의 수가 계속 커지게 되면 궁극적으로는 정규분포로 근사하기 때문이다.

정규분포는 여러 가지 장점을 지니고 있다. 그중에서도 가장 대표적인 장점은 표준화(standardization)가 가능하다는 점이다. 어떤 변수 $X$가 정규분포를 따른다고 하자. 또 변수 $X$의 모수인 모평균 $\mu$와 모분산 $\sigma^2$가 주어졌다고 하자. 이것을 흔히 $X \sim N(\mu, \sigma^2)$로 표기한다. 이제 $X$를 변환한 새로운 변수 $Z = \frac{(X-\mu)}{\sigma}$를 보자. 새로운 변수 $Z$도 모평균이 0이고 모분산이 1인 정규분포를 따른다는 사실이 증명되어 있다. 즉, $Z = \frac{(X-\mu)}{\sigma} \sim N(0, 1)$로 표기할 수 있는 것이다. 이것을 표준정규분포라고 부른다.

이제 모수 $\mu$와 $\sigma^2$가 어떤 값을 갖든 간에, 변수 $X$가 정규분포를 따르기만 하면 모두 표준정규분포를 따르는 $Z$로 변환할 수 있다. 또 거꾸로 $X = \mu + Z\sigma$의 식을 이용하여 $X$로 되돌아갈 수도 있다. 그러므로 $Z$에 대한 확률을 계산할 수 있는 표(table)만 만들어 놓으면, 모든 $X$의 확률도 이 표를 이용하여 계산할 수 있게 된다. 이 책의 부록 1과 2에 표준정규분포표와 누적표준정규분포표를 수록하였다.

그림 9-5는 중요한 분포들 간의 관계를 요약하여 보여 주고 있다.

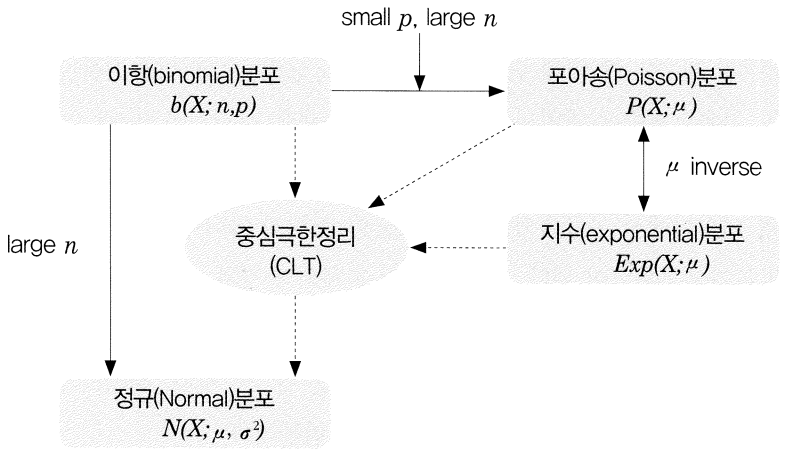



그림 9–5 **주요 확률분포 간의 관계도**

# 3 | 기술통계학

## 1. 기본개념

앞에서 통계의 기반이 되는 확률과 확률분포에 대해서 살펴보았다. 이번에는 본격적인 통계분석의 출발점이자 가장 기본이 되는 몇 가지 작업에 대해 알아보자. 첫째는 데이터를 요약하고 정리하여 전체적인 모양을 알아보는 작업이다. 이것은 데이터의 성격을 한눈에 보여 주는 '대표값'을 구하는 일로 이루어진다. 둘째는 통계분석에 필요한 예비자료 또는 기본정보를 만드는 작업이다. 나중에 좀 더 어렵고 복잡한 분석을 하기 위해 원래의 데이터를 분석에 용이한 형태로 가공하는 것이다. 셋째는 시각화 작업이다. 크고 복잡한 데이터는 숫자(numerical)로 요약할 수도 있지만 그림(visual)으로 보여 줄 수도 있다. 수치의 의미를 파악하기보다는 그림을 통해 직관적으로 이해하는 것이 더 효과적일 수 있기 때문이다.

위에서 말한 작업을 모두 통틀어 기술통계학(descriptive statistics)이라고 부른다. 기술통계

학은 용어가 의미하는 것처럼 데이터의 모습을 묘사하는(describe) 작업, 다시 말해 데이터를 구성하는 각각의 변수(X)에 대해 관측치들이 어떤 모양으로 나타나는지를 정리하여 보여 주는 작업이다. 기술통계학에 대비되는 개념이 추론통계학(inferential statistics)이다. 추론통계학은 표본을 이용하여 모집단의 특성을 추측하고(guess) 분석하는(analyze) 작업을 다룬다. 앞에서 본 예시적 데이터에서 사람들의 연령과 체중이 어떻게 나타나는지를 표나 그림으로 보여준다면 그것은 기술통계학이 된다. 하지만 국민 전체의 연령과 체중의 평균이 어느 정도인지, 또 연령과 체중 사이에는 어떤 관계가 있는지를 알아본다면 그것은 추론통계학이 된다. 따라서 기술통계학보다 더 복잡하고 어려운 수리적 지식을 필요로 한다. 뒤에서 알아볼 추정, 상관분석, 회귀분석 등은 모두 추론통계학에 해당되는 기법들이다.

기술통계학은 단순한 계산의 문제이고 사람보다는 컴퓨터가 하는 일 정도로 가볍게 생각하는 경향이 있다. 그러나 기술통계학을 통해 정리하고 가공한 정보들이 없으면 나중에 복잡한 추론통계학을 수행하는 것이 훨씬 어려워진다. 더구나 빅데이터의 시대에서 기술통계학의 의미와 용도는 더욱 커지고 있다. 현장 실무에서 더 자주 활용되는 기법들은 복잡하고 정교한 알고리즘보다는 오히려 기본적인 기술통계학 도구들이다.

## 2. 데이터 대표값

### 중심의 대표값

기술통계학의 첫 주제는 데이터 전체의 구조와 내용을 잘 요약하고 정리할 수 있는 대표값을 찾는 일이다. 그렇다면 대표값에는 어떤 것들이 있을까? 가장 기본이 되는 대표값은 데이터의 '중심(center)'이 어디에 있는지를 나타내는 값이다. 그 다음의 대표값은 중심을 가운데에 두고 데이터 값들이 퍼져 있는 '산포(dispersion)'의 정도를 보여 주는 값이다. 실제로 통계학의 역사를 보면 초기에는 '중심 또는 평균'의 분석에 초점을 맞추었다가 시간이 흐르면서 점점 '산포 또는 분산'의 중요성이 커지는 양상을 보인다.

데이터의 중심을 보여 주는 대표값은 중심을 어떻게 정의하느냐에 따라 달라진다. 통계에서 가장 많이 사용되는 중심의 대표값은 평균값(mean)이다. 특히, $n$개의 관측치($X_i$)로 이루어진 표본의 데이터에서 구한 아래의 표본평균(sample mean) $\bar{x}$가 일차적인 중심의 대표값으로 사용된다.

$$\bar{x} = \frac{\Sigma X_i}{n}$$

다음으로 생각할 수 있는 중심의 대표값은 중앙값(median)이다. 데이터를 작은 값에서부터 크기 순으로 한 줄로 세웠을 때 가운데 위치에 있는 값을 가리킨다. 일반적으로 중심의 대표값으로 평균값이 중앙값보다 더 자주 이용되는 이유는 평균은 계산 과정에 모든 데이터를 다 포함시키지만 중앙값은 단지 크기의 순서를 나타내는 일부의 정보만 사용하기 때문이다. 그러나 보는 시각에 따라서는 중앙값이 평균보다 중심의 위치를 더 잘 나타낸다고 할 수도 있다. 왜냐하면 평균은 너무 큰 값이나 너무 작은 값과 같은 극단적인 값의 영향을 많이 받지만 중앙값은 단지 순서의 위치만 보지 차이의 크기를 보지는 않기 때문이다. 최빈값(mode)도 대표값이 될 수 있다. 관측치의 빈도가 가장 높은 값이 바로 최빈값인데, 이 값도 중심의 성격을 지니는 것이다.

## 산포의 대표값

다음에 알아볼 것은 데이터의 산포를 나타내는 대표값이다. 데이터의 산포 정도는 데이터 값들이 가운데의 중심을 기준으로 얼마나 좌우로 퍼져 있는지에 의해 결정된다. 데이터의 산포는 각각의 데이터 값과 평균값의 차이에 의해 결정된다. 표본의 평균이 $\bar{X}$일 때, 각각의 데이터 값 $X_i$에 대해 $(X_i - \bar{X})$의 크기를 본다는 것이다. 여기서 $(X_i - \bar{X})$를 평균보정 데이터(mean-adjusted data)라고 부른다. 이 값이 작으면 그 데이터는 중심으로부터 가깝다는 뜻이고 이 값이 크면 멀다는 뜻이다.

평균보정 데이터는 관측치와 평균과의 차이를 가리키므로 이 값들의 합(sum)을 보면 전체 데이터의 분포 정도를 알 수 있다. 만일 그 값이 매우 크다면 평균을 중심으로 데이터들이 넓게 퍼져 있다는 뜻이고, 작다면 가운데에서 멀지 않은 좁은 범위에 몰려있다는 뜻이 된다. 문제는 평균보정 데이터를 모두 더한 합이 0이 된다는 데 있다. 따라서 합을 구하는 것은 아무 의미가 없다. 그렇다면 어떻게 이 문제를 해결할 수 있을까? 크게 두 가지를 생각할 수 있다. 하나는 절댓값(absolute value)인 $|X_i - \bar{X}|$로 만드는 것이다. 이렇게 하면 당연히 음의 값은 모두 양의 값으로 바뀌면서 합도 의미를 가질 수 있게 된다. 다른 하나는 제곱값(square)인 $(X_i - \bar{X})^2$으로 만드는 것이다. 이렇게 하여도 음의 값이 모두 양의 값으로 바뀌면서 문제를 해결할 수

표 9-2 원 데이터와 평균보정 데이터의 비교

| 관측대상(O) | 원래 데이터 (original data) | | 평균보정 데이터 (mean-adjusted data) | |
|---|---|---|---|---|
| | 신장($X_1$) | 체중($X_2$) | 신장($X_1$) | 체중($X_2$) |
| 평균(mean) | 167.5 | 65.9 | 0 | 0 |
| 제곱합(SS) | 994.4 | 1364.4 | 994.4 | 1364.4 |
| 분산(variance) | 82.9 | 113.7 | 82.9 | 113.7 |

있다. 통계학에서는 절댓값을 쓰는 경우도 있지만 대부분은 제곱값을 사용한다. 이때 제곱값을 모두 더한 값인 $\Sigma(X_i-\bar{X})^2$이 바로 제곱합(Sum of Squares: SS)이 된다. 보다 정확하게 말하면, 평균보정 데이터의 제곱을 모두 더한 값이 된다.

원래의 데이터(original data)와 평균보정(mean-adjusted) 데이터를 비교해보자. 표 9-2에 하나의 표본 데이터가 예시적으로 주어져 있다. 여기에서는 신장($X_1$)과 체중($X_2$)의 두 변수에 대한 관측치가 주어져 있다. 원 데이터와 평균보정 데이터의 공통점과 차이점을 살펴보자. 표에서 보는 것처럼 원 데이터와 달리 평균보정 데이터의 합(sum)은 0이다. 따라서 평균도 0이 된다. 그러나 원 데이터와 평균보정 데이터의 제곱합은 동일하다. 평균보정 데이터의 평균은 0이지만 제곱합은 원 데이터와 같다는 사실은 매우 중요한 성질이기 때문에 잘 기억해두기로 하자.

위에서 정의한 제곱합을 이용하여 표본분산(sample variance)이라는 산포의 대표값을 만들게 된다. 표본분산은 흔히 $s^2$으로 표기하며 $n$개의 관측치($X_i$)로 이루어진 표본의 표본분산은 아래와 같이 정의된다.

$$s^2 = \frac{\Sigma(X_i-\bar{X})^2}{n-1}$$

표본분산을 대표값으로 쓰게 되면 한 가지 문제가 생길 수 있다. 여기서 $s^2$은 원래의 변수 $X$가 아니라 그것의 제곱인 $X^2$으로 만들어지는 값이다. 따라서 원래 단위의 데이터보다 그 값이 훨씬 커지는 문제가 발생한다. 그러므로 $s^2$이 아니라 제곱근($\sqrt{\ }$)을 통하여 제곱을 하기 전의 원래의 단위로 돌려준 $s$를 산포의 대표값으로 쓸 수도 있다. 이것이 바로 표본의 표준편차(Standard Deviation : SD)이다.

다음으로 생각할 수 있는 산포의 대표값은 사분위수(quantile)이다. 사분위수는 크기의 순

서에 따라 늘어놓은 자료를 넷으로 나누는, 즉 사등분하는 수이다. 특히 그중의 첫 번째 사분위수를 제1사분위수, 세 번째 사분위수를 제3분위수라고 한다. 두 번째 사분위수는 앞에서 정의한 중앙값(median)이 된다. 이때 사분위수의 범위는 아래와 같이 제3사분위수와 제1사분위수의 차이로 정의한다. 이 값도 산포의 정도를 보여 주는 대표값으로 사용될 수 있다. 또 다른 대표값은 자료의 최댓값과 최솟값의 차이다. 이 차이를 범위(range)라고 하며 이것도 산포의 정도를 보여 주는 값이 된다.

## 3. 데이터 시각화

기술통계학에서는 수치로 요약한 정보를 제공하기도 하지만 동시에 시각적으로 요약한 정보를 제공하기도 한다. 이미 앞에서 설명한 것처럼, 시각화를 하는 이유는 다음 두 가지를 들 수 있다. 첫째는 시각적 정보의 전달효과가 높기 때문이다. 둘째는 숫자로는 드러나지 않던 정보가 그림을 통해서는 나타나는 경우들이 있기 때문이다.

어떤 모양의 시각적 표현이 가장 효과적이라고 한마디로 말할 수는 없다. 왜냐하면 데이터의 특성에 따라서 또 통계작업의 목적에 따라서 효과적인 시각적 표현이 달라지기 때문이다. 대표적으로 자주 사용되는 시각화의 도구들은 다음과 같다.

### 표

표(table)는 가장 일차적인 시각화의 도구이다. 일단 표로 정리하면 그것을 바탕으로 다른 모양의 시각화 도구들을 사용할 수 있기 때문이다. 표는 흔히 행렬(matrix) 형태로 보여 준다. 전체 데이터 값을 여러 구간으로 나눈 후 관측치들이 어느 구간에 얼마나 분포되어 있는지를 정리한 도수분포표가 대표적인 모양이다.

### 차트

차트(chart)는 주로 분포를 알아보는 데 사용되는 시각적 도구이다. 여기에도 여러 가지 형

태가 있고 각각은 용도가 다르다. 그중에서도 바 차트(Bar chart), 파레토 차트(Pareto chart), 파이 차트(Pie chart) 등이 자주 사용된다.

## 히스토그램

히스토그램(histogram)은 앞에서 설명한 도수분포표를 근거로 작성하는 시각화 도구이다. 흔히 동일한 폭을 갖는 계급으로 나누어 각 계급의 도수(frequency)를 기둥 형태로 표현하는 식으로 만든다.

## 줄기잎 그림

줄기잎 그림(stem and leaf plot)은 관측치들을 줄기에 해당되는 부분으로 크게 나눈 후 각 줄기에 소속되어 있는 관측치들을 잎에 해당되는 부분으로 작게 나누어 시각적으로 표현하는 도구이다. 예를 들어, 시험점수의 데이터라고 하면 먼저 60점대, 70점대, 80점대 등 10점대로 줄기를 만든 후 그 줄기에 소속되는 관측치들을 잎으로 배치시키는 식으로 만들게 된다. 모든 관측치가 그림 안에 반영되기 때문에 정보의 손실이 없고 전체의 모양을 이해하기 쉽다는 장점이 있다.

## 지도와 네트워크

조사 대상의 전체 집합(예를 들어 세계, 국가 등)을 보여 주는 실제의 지도(map) 위에 관측치들의 값을 표시하거나, 조사 결과를 정리하여 지도 모양의 그림으로 표현하는 방식을 가리킨다. 또 관측치들 간의 관계를 노드(node)와 화살표(arrow)로 이루어지는 네트워크(network) 모양으로 보여 줄 수도 있다.

# 4 | 모수추정

## 1. 추정의 방법

이미 여러 번 설명한 것처럼, 통계적 분석의 핵심은 추정이다. 표본의 통계량을 가지고 모집단의 속성인 모수를 알아내는 작업인 것이다. 추정의 출발은 추정값으로 사용할 추정량의 선택에 있다. 왜냐하면 하나의 모수에 대해 우리가 사용할 수 있는 추정량은 여러 개 있을 수 있고 그 가운데 어떤 추정량을 사용하느냐에 따라 추정의 결과가 달라지기 때문이다. 예를 들어, 모평균이라는 모수의 참값을 추정하는 문제를 생각해 보자. 추정을 위해 먼저 표본을 추출하였다. 이제 표본으로부터 얻을 수 있는 다양한 통계량 중에 어느 것을 추정량으로 사용할 것인가? 바로 생각할 수 있는 후보만 해도 여러 개가 있다. 우선 표본의 평균을 쓸 수 있다. 하지만 표본평균 대신 표본의 중앙값을 쓸 수도 있고, 아니면 아주 간단하게 가장 큰 값과 가장 작은 값을 평균한 값을 쓸 수도 있다.

유일한 최선(unique and best)의 추정량을 미리 알 수는 없다. 왜냐하면 모수는 알려지지 않은 값이기 때문이다. 정답을 모르는데, 어느 추정량이 정답인지를 알 수는 없는 것이다. 그러나 여러 개의 좋은(many good) 추정량을 얻을 수는 있다. 그렇다면 어떤 추정량이 과연 좋은 추정량일까? 이 질문에 대한 답을 위해서는 좋은 추정량으로서 갖추어야 할 기준과 조건이 설정되어야 한다(기준과 조건에 대한 자세한 설명은 이 책의 범위를 벗어나기 때문에 생략하기로 한다).

앞의 예로 돌아가서, 100명의 표본을 뽑아서 그들의 키를 재었더니 평균값이 170.6cm로 나왔다고 하자. 이 정보를 바탕으로 모집단의 평균 신장이 얼마냐고 물어본다면 대부분은 170.6cm라고 대답할 것이다. 모평균 $\mu$에 대한 가장 합리적인 추정치는 표본평균 $\bar{X}$가 된다는 것이다. 그런데 그렇게 생각하는 근거가 무엇이냐, 표본평균 대신 중앙값과 같은 다른 통계량을 사용하면 왜 안 되느냐고 물어보면 명확한 대답을 찾기가 쉽지 않다. 그냥 상식적으로 판단하면 그렇다, 또는 중·고등학교 때부터 그렇게 배워서 습관적으로 대답한다 등의 답변을 내놓을 것이다. 그러나 모평균의 추정량으로 표본평균을 사용하는 것은 그냥 상식적인 판단 때문이 아니라 그것이 가장 좋은 추정량의 요건을 만족시키기 때문이다. 추정량이 될 수 있는 여

러 후보 가운데 표본평균이 가장 좋은 후보로서의 자격을 갖추고 있는 것이다.

그렇다면 어떤 방법으로 기준과 조건을 만족시키는 좋은 추정량을 찾을 수 있을까? 이 주제를 다루는 것이 추정방법(estimation method)이다. 통계학의 역사가 오래되면서 다양한 추정방법이 개발되었고, 각각의 방법은 장점과 단점을 지니고 있다. 이 가운데 가장 자주 사용되는 두 가지 추정방법만 간략히 이해하고 넘어가자.

가장 폭넓게 사용되는 추정방법은 최우도추정법(maximum likelihood estimation method)이다. 이 방법의 논리는 간단하고 분명하다. 표본의 관찰치(observation value)가 모집단의 모수값(parameter value)과 일치할 '가능성(likelihood)'을 우도라고 할 때, 우도가 최대가 되도록 추정한다는 것이다. 여기서 확률 대신 우도라는 용어를 사용하는 이유는, 모수의 참값은 알 수 없기 때문에 당연히 확률을 알 수는 없고 단지 가능성의 정도만 알 수 있기 때문이다. 이 방법은 논리도 합리적이고 좋은 추정의 여러 가지 요건을 만족시키기 때문에 가장 폭넓게 사용된다.

다른 하나는 최소제곱추정법(least squares estimation method)이다. 이 방법의 기준도 명확하다. 표본의 관찰치(observation value)와 모집단의 모수값(parameter value)의 차이인 '오류(error)'의 제곱을 모두 더한 값이 최소가 되도록 추정한다는 것이다. 이 방법의 장점은 계산이 용이하다는 점이다. 뒤에서 설명할 회귀분석에서는 주로 이 추정방법을 사용한다.

## 2. 점추정과 구간추정

위에서 설명한 추정방법을 통해 실제로 '무엇'을 추정할지에 대해 생각해 보자. 추정의 대상은 매우 다양하다. 모집단의 속성을 설명하는 모든 모수가 추정의 대상이 될 수 있다. 그중에서 가장 대표적인 추정의 대상이 되는 모수는 모평균과 모분산이다. 앞에서 예를 든 제약회사의 데이터베이스에서, 연령($X_1$)이라는 변수에 대해 연령의 모평균과 모분산을 추정하고, 혈압($X_3$)이라는 변수에 대해서도 혈압의 모평균과 모분산을 추정하는 식이다. 여기서 모평균과 모분산의 두 가지 모수가 대표적 모수가 되는 이유는 무엇일까? 그것은 이 두 개의 모수가 모집단의 중심과 범위를 가장 잘 보여 주기 때문이다. 따라서 이 모수들의 값을 정확히 추정할 수 있으면 모집단의 구조와 형태를 한눈에 파악할 수 있는 것이다.

추정은 하나의 값으로 할 수도 있고 범위의 값으로 할 수도 있다. 표본에서 추출한 하나의 통계량 값으로 모수를 추정하는 것이 점추정(point estimation)이다. 또 범위의 값으로 추정하

는 것이 구간추정(interval estimation)이다. 점추정은 모수 $\theta$에 통계량 $\hat{\theta}$를 바로 대입하여 추정한다. 점추정은 간단하다는 장점이 있지만 통계량 값이 모수값과 일치할 확률은 0이라는 치명적 단점이 있다. 그러므로 일반적으로는 하나의 값이 아니라 범위의 값으로 추정을 하게 된다. 즉, 모수값이 존재할 상한과 하한으로 이루어지는 구간추정을 하게 된다. 구간은 넓게 정할 수도 있고 좁게 정할 수도 있다. 넓게 정할수록 모수가 그 안에 속할 확률은 높아지지만 정보의 가치는 떨어진다. 따라서 실제의 구간추정에서는 구간의 넓이를 결정하는 신뢰수준(confidence level)인 $1-\alpha$ 값을 설정하여 구간의 넓이를 정한다. $\alpha$ 값의 변화에 따라 구간의 넓이를 다르게 정하는 것이다. $1-\alpha$ 값이 정해지면, 이것을 기준으로 구간의 상한값($\hat{\theta}_U$)과 하한값($\hat{\theta}_L$)을 정하게 된다. 이 값은 모수값이 상한과 하한 안에 포함될 확률이 적어도 $1-\alpha$보다는 크게 함으로써 정할 수 있다. 즉, $P(\hat{\theta}_L < \hat{\theta} < \theta_U) \geq 1 - \alpha$이 되도록 구간의 넓이를 정하는 것이다.

# 5 | 상관분석

## 1. 기본 개념

앞에서 우리는 특정변수의 추정에 대해 알아보았다. 앞의 데이터베이스 예로 돌아가 보면, 연령이라는 변수나 혈압이라는 변수 각각의 모평균이나 모분산을 추정한 것이다. 이제부터는 분석의 범위를 넓혀 변수와 변수 사이의 관계에 대해 생각해 보자. 즉, 연령과 혈압 사이에 무슨 관계가 있는지를 알아보는 것이다.

통계적 분석에서, 변수 간의 관계를 추정하는 가장 일차적인 분석이 바로 상관분석(correlation analysis)이다. 상관분석을 이해하기 위해 먼저 작은 예를 생각해 보자. 어떤 변수 $X$와 $Y$가 있다고 하자. 각각의 변수에 대해 $n$개의 표본을 추출한 후, 표본평균 $\bar{X}$와 $\bar{Y}$를 각각 계산한다. 다음으로 각 표본에서 한 개씩의 관찰치를 뽑아서 $X$와 $Y$의 쌍(pair)을 만들자. 그러면 모두 $n$개의 쌍이 만들어진다. 이것을 가지고 두 변수의 관계를 어떻게 측정할 수 있을까? 상관

분석의 기본 아이디어는 두 변수가 움직이는 패턴을 분석하는 것이다. 즉, $X$와 $Y$의 값을 쌍으로 보았을 때, $X$값과 $Y$값이 함께 비슷한 방향으로 움직이는지 아니면 반대 방향으로 움직이는지, 아예 제각각으로 움직이는지를 보고 관계를 파악하자는 것이다.

그러면 이 움직이는 패턴을 어떻게 정량화할 수 있을까? 상관분석에서는 우선 다음의 지표 $S_{xy}$를 제시한다.

$$S_{xy}=\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})=\sum_{i=1}^{n}x_iy_i-(\sum_{i=1}^{n}x_i)(\sum_{i=1}^{n}y_i)/n$$

단, $\bar{x}=X$의 표본평균, $\bar{y}=Y$의 표본평균

이 지표는 두 변수 간 관계의 강도(strength)와 방향(direction)을 보여 준다. 우선 이 지표의 값이 크면 두 변수 사이에 강한 상관관계가 있다고 할 수 있다. 또 이 지표의 부호가 양(positive)의 값을 가지면 두 변수가 같은 방향으로 움직이고 부(negative)의 값을 가지면 반대 방향으로 움직인다고 할 수 있다. 하지만 이 지표의 결정적 문제점은 변수의 단위(scale)에 큰 영향을 받는다는 것이다. 하나의 변수가 kg 단위인 데 반해 다른 변수가 mg의 단위라면 상관관계를 제대로 측정하기 어렵다. 따라서 단위의 영향을 제거한 새로운 지표가 필요하다. 여기서 제시된 것이 다음의 지표 $r$이다.

$$r=\frac{S_{xy}}{\sqrt{\sum(x_i-\bar{x})^2}\sqrt{\sum(y_i-\bar{y})^2}}=\frac{S_{xy}}{\sqrt{S_{xx}}\sqrt{S_{yy}}}$$

이 지표가 바로 상관계수(correlation coefficient)이다. 상관계수는 $-1\leq r\leq 1$ 의 값을 갖도록 설계되어 있기 때문에 단위에 상관없이 두 변수 사이의 '상대적' 관계를 제대로 반영할 수 있다. 따라서 상관계수의 크기와 부호를 바탕으로 상관분석을 하게 된다. 실무적으로 상관관계를 판정하는 가이드라인은 없을까? 일반적으로 다음의 표와 같은 해석을 할 수 있다. 그러나 이 가이드라인은 절대적인 기준이 아니다. 어느 상황에서 어떤 목적을 위해 상관분석을 하는지에 따라 같은 값에 대한 해석은 달라질 수 있다. 예를 들어, 아주 정밀한 과학적 현상에 대해서는 상관계수 0.7도 낮은 수준이라고 할 수 있지만, 사회과학적 분석에서는 상관계수 0.5도 높은 수준이 될 수도 있는 것이다.

| 상관계수 값 | 의미의 해석 |
|---|---|
| -1.0과 -0.7 사이 | 강한 음의 상관관계 |
| -0.7과 -0.3 사이 | 뚜렷한 음의 상관관계 |
| -0.3과 -0.1 사이 | 약한 음의 상관관계 |
| -0.1과 0.1 사이 | 무시할 수 있는 정도의 상관관계 |
| 0.1과 0.3 사이 | 약한 양의 상관관계 |
| 0.3과 0.7 사이 | 뚜렷한 양의 상관관계 |
| 0.7과 1.0 사이 | 강한 양의 상관관계 |

또한 상관계수는 두 변수 사이의 선형(linear) 관계만을 나타낸다는 사실을 기억해야 한다. 선형 관계에 초점을 맞추는 이유는 그것이 가장 일반적인 현상이고 또 단순한 관계이기 때문이다. 나아가 상관성의 크기를 정량적으로 측정할 수 있는 상관계수가 폭넓게 사용되고 있기 때문이다. 그러나 세상에는 선형이 아니라 비선형(non-linear) 모양의 상관관계를 보여주는 경우도 종종 있다. 그럴 때는 그 경우에 맞는 새로운 기준과 계수로 상관관계를 파악해야 한다.

## 2. 예제

개인의 소득수준과 스마트폰 사용량 간에 어떤 상관관계가 있는지를 알아보려고 한다. 상관분석을 위해, 변수 $X$에 연간소득을 그리고 변수 $Y$에 통신비를 놓은 뒤 10명의 가입자들로부터 표 9-3의 데이터를 수집하였다.

표 9-3 **소득과 통신비 데이터** (단위 : 천 원)

| 가입자 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 |
|---|---|---|---|---|---|---|---|---|---|---|
| 소득($X$) | 2,000 | 2,200 | 2,500 | 2,800 | 3,200 | 3,600 | 4,100 | 4,700 | 5,300 | 6,000 |
| 통신비($Y$) | 25 | 28 | 22 | 38 | 41 | 32 | 31 | 45 | 60 | 48 |

앞의 식에 넣어서 상관계수를 구하였더니 $r = 0.816$으로 나타났다(물론 실제로는 수작업으로

계산하는 것이 아니라 통계패키지를 돌려서 값을 얻는다). 상관계수가 이 정도라면 소득수준과 사용량 간에는 높은 양의 상관관계가 존재한다고 할 수 있다. 하지만 주의할 점은, 바로 뒤의 회귀분석에서 설명하겠지만, 상관계수가 크다고 해서 이를 두 변수 사이에 인과관계가 존재하는 것으로 해석해서는 안 된다는 것이다. 단지 소득이 많은 사람들이 스마트폰을 더 많이 사용하는 일반적인 패턴이 보인다는 정도만 말할 수 있지, 소득수준이라는 변수의 변화가 통신비라는 변수의 변화를 일으키는 원인이 된다는 말은 할 수 없다는 것이다.

# 6 | 회귀분석

## 1. 기본 개념

앞에서 살펴본 상관분석은 겉으로 드러난 두 변수 사이의 움직임을 단지 관찰한 결과일 뿐이다. 움직이는 패턴이 비슷한지, 반대인지, 아니면 독립적인지 만을 보기 때문에 두 변수 사이에 어떤 근본적이고 구조적인 관계가 존재하는지, 특히 하나의 변수가 다른 변수에 어떤 영향을 미치는지를 알 수는 없다. 우연한 상관관계를 넘어, 원인과 결과의 인과관계(causal relationship)를 파악하는 과제에 가장 자주 사용되는 통계적 방법론으로 회귀분석(regression analysis)을 들 수 있다. 회귀분석은 워낙 널리 쓰이는 통계적 분석방법이므로 기본 이론을 잘 이해할 필요가 있다.

상관분석과 회귀분석의 개념적 차이를 설명하기 위해, 이차원 평면 위에 두 변수 $X$와 $Y$의 값들이 흩어져 있는 상황을 생각해 보자. 먼저 변수 $X$와 $Y$가 서로 대등한(independent and uncontrolled) 입장에 있다고 할 때, 둘 사이의 상관성을 알아보기 위해서는 $X$와 $Y$가 각각의 평균인 $\bar{X}$와 $\bar{Y}$를 중심으로 흩어져 있는 패턴이 얼마나 비슷한지를 보면 된다. 그 정도를 측정한 값이 바로 앞에서 알아본 상관분석의 상관계수(correlation coefficient)이다.

이번에는 변수 $X$가 원인이 되고 $Y$가 결과가 되는 인과관계에 있다고 가정하자. 이 상황에

서는 두 변수 사이의 유사성이 아니라 한 변수가 다른 변수에 미치는 영향(effect)의 크기를 알아보는 것이 분석의 주제가 된다. 그렇다면 어떻게 그 크기를 알아볼 수 있을까? $X$가 한 단위 늘어났을 때 Y는 몇 단위 늘어나는지를 보는 것이 가장 단순하면서도 확실한 방법이 될 것이다. 그러기 위해서는 $Y = \alpha + \beta X$ 형태의 선형함수(linear equation)를 만들어서 그 선의 기울기(slope) $\beta$와 절편(intercept) $\alpha$의 값을 추정하면 된다. 이것이 회귀분석의 기본 원리이다.

따라서 회귀분석은 두 개의 변수에 대해 하나를 종속변수(dependent variable)로, 나머지를 독립변수(independent variable)로 하는 함수로 만들어서 둘 사이에 인과관계가 존재하는지, 존재한다면 어느 정도인지를 분석하는 통계적 기법이다. 여기서 독립변수는 종속변수에 영향을 주는 변수로서 원인이 되는 것이고, 종속변수는 독립변수에 영향을 받는 변수로써 결과가 되는 것이다. 예를 들어, 어느 서비스 기업에서 광고투자 비용과 매출액 간의 관계를 분석하려 한다고 하자. 그러면 광고비는 독립변수가 되고 매출액은 종속변수가 된다. 이때, 광고비가 얼마가 늘어나면 그에 따라 매출액은 얼마나 늘어날 것인지, 즉 둘 사이의 인과관계를 보여주는 함수를 찾는 것이 바로 회귀분석이다. 따라서 회귀분석은 독립변수와 종속변수 간의 관계를 수학적으로 표현한 회귀식(regression equation)을 추정함으로써, 두 변수 간의 관계를 규명하게 된다.

## 2. 회귀식

회귀분석은 독립변수의 개수에 따라, 독립변수가 하나인 단순 회귀분석(simple regression)과 독립변수가 두 개 이상인 다중 회귀분석(multiple regression)으로 나눈다. 하지만 단순 회귀분석이든 다중 회귀분석이든 기본 원리나 이론적 근거는 동일하기 때문에 여기서는 단순 회귀분석에 대해서만 살펴보도록 한다.

단순 회귀분석의 기본 모형, 즉 회귀식(regression equation)은 다음과 같다.

$$Y_i = \alpha + \beta X_i + \varepsilon_i$$

여기서, $X_i$는 독립변수, $Y_i$는 종속변수, $\alpha$는 회귀식의 $y$절편, $\beta$는 회귀식의 기울기, $\varepsilon_i$는 회귀식에 의해 설명될 수 없는 오차(random error)를 나타낸다.

## 3. 모수추정

독립변수와 종속변수가 선형(linear) 관계를 갖는다는 가정하에, 두 개의 모수(parameter), 즉 $\alpha$와 $\beta$를 추정(estimation)하여 회귀식을 얻을 수 있다. 이론적으로는 무수히 많은 $\alpha$와 $\beta$값이 있을 수 있고 따라서 무수히 많은 회귀식이 나올 수 있다. 그러므로 회귀분석의 핵심과제는 가장 적합한 모수의 추정을 통해 최적의 회귀식을 찾는 일이 된다.

모수를 추정하는 방법에는 여러 가지가 있지만, 회귀분석에서는 앞에서 설명한 최소제곱법(least square method)을 사용한다. 최소제곱법의 아이디어는 간단하다. 그림 9-6에서 보듯이, 실제값인 $Y_i$와 그것의 추정치인 $\hat{Y}_i$의 차이를 오차(error)라고 한다. 좋은 회귀식이 되려면 오차를 모두 합한 값이 작아야 한다. 따라서 오차의 제곱합이 최소(minimum)가 되는 $\alpha$와 $\beta$값을 추정하면 된다. 여기서 오차의 합 자체가 아니라 제곱합을 쓰는 이유는, 제곱을 하지 않은 오차의 경우 양(+)이 될 수도 있고 음(−)이 될 수도 있어 오차의 합을 최소화한다는 것이 의미가 없기 때문이다.

최소제곱법으로 $\alpha$와 $\beta$의 추정하는 과정에는 우리가 흔히 최소화 문제를 풀 때 사용하는 방법을 사용한다. 즉, 미분한 후 그 식을 0으로 놓은 연립방정식을 푸는 것이다. 이 연립방정식을 정규방정식(normal equation)이라고 한다. 약간의 수학적 작업을 거쳐 최소제곱법에 의해 $\alpha$와 $\beta$의 추정치를 구하면 다음과 같다. 다음 식에서 $n$은 회귀분석에 사용한 표본의 수를 의미한다.

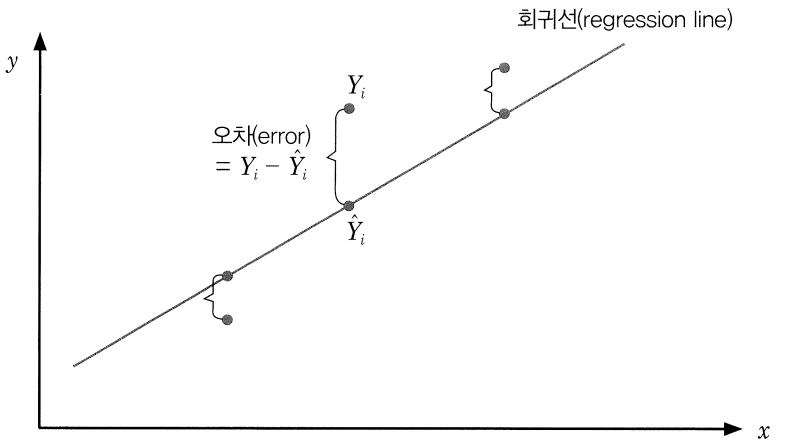



그림 9-6 **최소제곱법의 도식화**

$$\hat{\beta} = \frac{n\sum XY - \sum X \sum Y}{n\sum X^2 - (\sum X)^2}$$

$$\hat{\alpha} = \frac{\sum Y - \hat{\beta}\sum X}{n}$$

이렇게 얻어진 회귀식의 설명력이 어느 정도인가, 즉 회귀분석에 의한 추정치가 실제값과 얼마나 잘 일치하는가를 알아보기 위해서는 흔히 결정계수(coefficient of determination)라고 불리는 $R^2$값을 이용한다. 결정계수는 다음과 같은 식으로 나타낼 수 있다. 이 식에서 분모는 데이터 전체에서 만들어지는 오차의 합을 나타내고 분자는 회귀식에서 만들어지는 오차의 합을 나타낸다. 그러므로 결정계수의 값이 커질수록 전체 오차에서 회귀모형으로 설명할 수 있는 오차의 상대적 비중이 커진다는 의미이고, 따라서 회귀분석의 적합도가 높아진다고 해석할 수 있다.

$$R^2 = \frac{(n\sum XY - \sum X \sum Y)^2}{\{n\sum X^2 - (\sum X)^2\}\{n\sum Y^2 - (\sum Y)^2\}}$$

결정계수값의 범위는 0과 1 사이로, 그 값이 클수록 설명력이 높은 것이다. 예를 들어, 결정계수의 값이 1이면 실제값과 추정치가 모두 일치하는 경우이다. 물론 현실에서 그러한 경우가 나올 수는 없기 때문에 대부분의 경우에는 1에 가까운 값이 나오기를 기대한다. 여기서 $R^2$의 값이 어느 정도 커야 되는지에 대한 절대적인 기준은 없다. 흔히 $R^2$이 0.6보다 크면 모형의 유의성이 충분하다고 판정하는 것을 볼 수 있다. 그러나 이것은 절대적인 기준은 아니다. 회귀분석은 이공계는 물론 사회과학, 인문학, 경영학, 의학, 문화예술 등 거의 모든 분야에서 폭넓게 쓰이고 있다. 그리고 분야의 본질적 특성에 따라 데이터의 변동성은 큰 차이가 난다. 그러므로 $R^2$의 높고 낮음은 분야의 특성을 고려하여 신축적으로 정하게 된다.

## 4. 예시

광고는 신규 고객을 늘리는 데 매우 효과적인 수단이라고 할 수 있다. 광고비와 신규고객

수 간의 관계를 실증적으로 분석하기 위하여 표 9-4에 나타난 것과 같이 10개 기업을 대상으로 한 해 동안의 광고비와 신규고객 수를 조사하였다.

표 9-4 10개 기업의 광고비 투자액과 신규고객 수 데이터

| 기업 | X : 광고비(억 원) | Y : 신규고객(100명) |
|---|---|---|
| A | 36.5 | 14 |
| B | 28.0 | 9 |
| C | 42.9 | 15 |
| D | 52.0 | 20 |
| E | 51.5 | 21 |
| F | 53.8 | 25 |
| G | 25.4 | 9 |
| H | 37.2 | 13 |
| I | 50.9 | 20 |
| J | 29.2 | 10 |

표 9-4의 자료를 토대로 광고비와 신규고객 수 간의 인과관계를 알아보기 위해 회귀분석을 실시하였다. 여기서는 광고비를 독립변수($X_i$)로, 신규고객 수를 종속변수($Y_i$)로 한 단순 회귀모형을 사용하였다.

$\sum XY = 6{,}895.2$, $\sum X = 407.4$, $\sum Y = 156.0$, $\sum X^2 = 17{,}679.8$이므로

$$\hat{\beta} = \frac{10(6{,}895.2) - (407.4)(156.0)}{10(17{,}679.8) - (407.4)^2} = 0.4987$$

$$\hat{\alpha} = \frac{156.0 - (0.4987)(407.4)}{10} = -4.7172$$가 된다.

따라서 추정된 회귀식은 다음과 같다.

$$\hat{Y}_i = -4.7172 + 0.4987 X_i \quad (\text{신규고객 수} = -4.7172 + 0.4987 \times \text{광고비})$$

여기서 회귀식의 결정계수($R^2$) 값을 계산해 보면 0.9465로 매우 높게 나타난다. 따라서 광고비 지출과 신규고객 증가 사이에는 통계적으로 유의한 인과관계가 존재한다고 할 수 있다.

# 7 | 실험적 분석

## 1. 기본 개념

통계적 분석에 이어서 실험적 분석에 대해 간략하게 살펴보자. 실험적 분석을 다른 말로 표현하면 시뮬레이션(simulation) 분석이다. 물론 실험적 분석과 통계적 분석은 다른 분석기법이다. 하지만 두 기법은 많은 면에서 밀접하게 관련되어 있다. 시뮬레이션을 위해서는 확률이론에 대한 기본 지식이 필요하기 때문이다. 따라서 독립된 장(chapter)으로 만들지 않고 통계적 분석의 끝에 추가하는 식으로 간략히 설명하려고 한다.

앞에서 설명한 것처럼, 산업공학에서는 시스템의 문제를 해결하기 위해 일차적으로는 수리적 모형을 사용한다. 그러나 시스템이 너무 크고 복잡하며, 시스템이 움직이는 패턴도 불확실하고 더구나 시간에 따라 상태가 변하는 특성을 갖는 경우에는 수리적 접근이 어려워진다. 그렇다고 직접 현실시스템에서 실험을 하기에는 너무 많은 비용이 들고 제약도 많다. 이럴 경우 컴퓨터 모델링을 기반으로 하는 모의실험(simulation)이 유용한 대안이 될 수 있다. 시뮬레이션은 한마디로 '현실시스템을 단순한 모델로 설계하고 이 모델의 상태와 변화를 컴퓨터 실험을 통해 분석하는 과정'이다.

시뮬레이션을 통한 실험적 분석이 필요한 경우는 매우 다양하다. 예를 들어, 많은 생산설비가 돌아가는 거대한 공장에서 아침 9시에 공장의 가동을 시작하고 난 후 한 시간이 경과한 10시에 각 공정별로 얼마나 많은 대기가 존재하는지, 처리시간은 평균 얼마나 걸렸는지, 병목현상이 일어나는 공정은 어디인지 등을 알아보려고 한다. 동일한 분석을 한 시간 단위로 반복하고, 나아가 요일마다 차이가 있는지도 알아보고자 한다. 또 다른 예로, 은행 업무가 시작된

후 시간대별로 대기하고 있는 고객의 수, 고객이 은행 안에 머무르는 시간 등을 예측하는 경우도 생각할 수 있다. 이런 예들은 수리적 분석보다는 실험적 분석이 더 적합한 경우이다.

## 2. 시뮬레이션 모델

모든 산업공학기법이 그러하지만, 시뮬레이션도 모델링에서 출발한다. 모델을 만들기 위해서는 다음 몇 가지의 용어와 개념을 이해해야 한다. 먼저 상태변수(state variable)는 시스템의 특성을 설명하는 요인들을 변수로 설정한 것이다. 또한 시뮬레이션에서 분석하고자 하는 대상을 개체(entity)라고 한다. 또 이 개체가 갖는 특성을 속성(attribute)이라고 한다. 물론 하나의 개체는 여러 가지의 속성을 가질 수 있다. 자원(resource)은 시스템의 운영에 필요한 요소를 의미한다. 활동(activity)은 시스템의 변화를 가져오는 일을 뜻한다. 또한, 특정 시간에서 시스템의 모든 개체, 속성, 활동 등의 수준을 표현하는 것이 상태(state)이다. 마지막으로 사건(event)이라는 용어의 의미도 알아야 한다. 사건은 시스템의 상태를 변화시키는 일의 발생을 가리킨다.

스마트기기를 생산하는 공장의 예를 생각해 보자. 여기서는 공장 자체가 '시스템'이 된다. 다음으로, 생산부품이나 생산기계는 '개체'이다. 부품의 형태, 주문 수량, 기계의 성능, 고장률 등은 각 개체의 '속성'이 된다. 생산설비는 '자원'으로, 생산부품의 가공, 완제품의 가공, 기계의 가동 등은 시스템의 변화를 일으키는 '활동'이다. 한편, 어느 특정 시점에 각 개체들이 갖는 값들을 모아놓은 정보는 '상태'로 볼 수 있다. 가공을 위한 부품 로트(lot)가 새로 도착한 것, 또는 조립을 마친 완제품 로트가 공장을 나가는 것 등은 '사건'이 된다.

통신서비스라는 시스템을 생각해 보면, 메시지는 '개체'이고 문자의 길이는 그 개체의 '속성'이다. 메시지를 전송하는 행위는 '활동'이고 전송을 위해 대기하고 있는 전체 메시지의 수는 '상태'가 된다. 수신자가 메시지를 받는 것은 '사건'이다.

## 3. 시뮬레이션 유형

시뮬레이션은 크게 정적(static) 시뮬레이션과 동적(dynamic) 시뮬레이션으로 나눌 수 있다.

둘 사이의 차이는 시간(time) 변수가 있느냐 없느냐에 따라 결정된다. 정적 시뮬레이션은 말 그대로 시간의 변화 없이 어느 특정 시점에서 여러 변수들의 속성값이 어떻게 변하는지를 보는 실험이다. 이 실험은 흔히 몬테카를로(Monte Carlo) 시뮬레이션이라고도 불리며, 시뮬레이션에서 가장 먼저 사용되었던 컴퓨터 실험방식이다. 그에 반해 동적 시뮬레이션은 시간의 변화에 여러 속성들의 값이 어떻게 바뀌는가를 보는 실험이다.

정적 시뮬레이션을 이해하기 위해, 어느 전술 실험을 예로 들어보자. 실험의 목적은 새로 개발한 무기의 탄착점이 목표영역 안에 떨어질 확률이 어느 정도인지를 알아보는 것이다. 이동하면서 발사해야 하기 때문에 발사점이 일정할 수는 없고 확률적으로 어느 분포를 따르면서 그 범위 안에서 달라지게 된다. 따라서 발사점은 확률분포에 맞추어 컴퓨터가 임의(random)로 정하게 된다. 이런 실험을 반복하면서 매 실험마다 나타나는 탄착점의 위치를 확인하면 어느 정도의 확률로 목표를 맞출 수 있는지를 예측할 수 있다. 이것은 전형적인 정적 실험, 즉 몬테카를로 시뮬레이션이다. 왜냐하면 여기서 시간이라는 변수는 아무 의미가 없기 때문이다. 즉, 시간은 정해진 점에 고정시켜 놓고 실험만 여러 번 반복한 경우가 되는 것이다.

이에 비해, 동적 시뮬레이션은 시간의 변화가 결정적인 변수로 작용하는 실험이다. 앞에서 본 공장이나 은행의 예에서는, 시간의 흐름을 따라 끊임없이 새로운 사건이 발생하고 그에 따라 변수들의 상태도 달라지게 된다. 이 실험을 아침 9시부터 저녁 6시까지 계속한다거나 더 시간을 길게 하여 일주일간 지속한다던가 하면서 시스템의 상태가 어떻게 달라지는지를 보는 것이 동적 시뮬레이션이다.

우리가 일반적으로 말하는 시뮬레이션은 동적 시뮬레이션이다. 동적 시뮬레이션도 크게 이산적(discrete) 시뮬레이션과 연속적(continuous) 시뮬레이션으로 나눌 수 있다. 이산적 시뮬레이션은, 시스템의 상태가 시간의 흐름에 따라 이산적으로 변화하는 실험을 가리킨다. 즉, 새로운 사건이 일어나면 그 결과로 변수의 속성값이 이산적 수치로 바뀌는 것이다. 은행의 예를 생각해 보면, 은행 창구에서 시스템의 변화가 일어나는 사건은 고객이 은행업무를 보기 위해 도착하거나 일을 마치고 창구를 떠나는 경우이다. 이 두 사건이 발생할 때 비로소 시스템의 상태가 바뀌게 된다. 즉, 시간의 흐름을 연속적으로 관측할 필요가 없고 사건이 일어난 경우에만 측정하면 된다. 따라서 이 경우에는 이산적 시뮬레이션을 하게 된다. 이에 반해 연속적 시뮬레이션은 변수들의 속성값이 연속적 수치로 바뀌는 실험을 뜻한다. 예를 들어, 화학공정이나 제철공정의 경우에는 시간의 변화에 따라 액체의 흐름량(flow)이 연속적인 수치로 바뀌므로 연속적 시뮬레이션을 해야 한다.

여기서 주의할 것은, 시스템의 성격에 따라 적합한 시뮬레이션 모형이 달라지는 것이 아니라 변수의 속성에 따라 달라진다는 사실이다. 예를 들어, 통신서비스시스템의 시뮬레이션을 생각해 보자. 여기서 만일 전송을 기다리고 있는 메시지의 수가 변수라면 특정 시점에 따라 상태가 바뀌므로 이산적 시뮬레이션이 적합하다. 그러나 같은 통신시스템에 대해서도, 만일 전체 메시지 전송량의 흐름이 변수라면 시간의 흐름에 따라 메시지가 얼마나 전송되는가를 나타내는 함수로 시스템을 표현하는 연속적 시뮬레이션이 적합하다.

이 가운데 가장 자주 수행되는 실험이 동적-이산적(dynamic-discrete) 시뮬레이션이다. 시간의 변화를 따라간다는 측면에서 동적 시뮬레이션이고, 이산적 변수들의 주요 속성들이 어떻게 바뀌는가를 예측하는 측면에서 이산적 시뮬레이션이다. 이것을 흔히 discrete-event 시스템 시뮬레이션이라고 부른다. 여기에서는 이 유형의 시뮬레이션에 대해서만 간략히 알아보기로 한다.

## 4. 시뮬레이션 절차

시뮬레이션의 유형이 달라지는 것과 마찬가지로 시뮬레이션을 수행하는 과정과 절차도 문제의 특성과 분석의 목적에 따라 달라진다. 그러나 컴퓨터를 활용한 시뮬레이션을 수행하는 일반적인 절차는 그림 9-7과 같이 정리할 수 있다.

여기에서 한 가지 이해하고 넘어가야 할 문제는 verification과 validation이라는 용어의 차이이다. 우리말로는 모두 '검증'이라고 부르지만 실질적인 성격과 목적은 상당히 다르다. 먼저 'verification'은 프로그램을 만드는 단계에 관련된 용어이다. 컴퓨터 프로그램이 제대로 작성되어 잘 작동을 하는지? 프로그램의 플로차트(flow chart)가 논리적으로 구성되었는지? 등을 확인하는 것이다. 이에 비해 'validation'은 모델의 수립과 관련된 용어이다. 즉, 모델이 시스템의 현실을 제대로 반영하고 있는지, 시스템의 핵심 변수들과 속성들이 모델에 잘 표현되어 있는지 등을 확인하는 것이다.

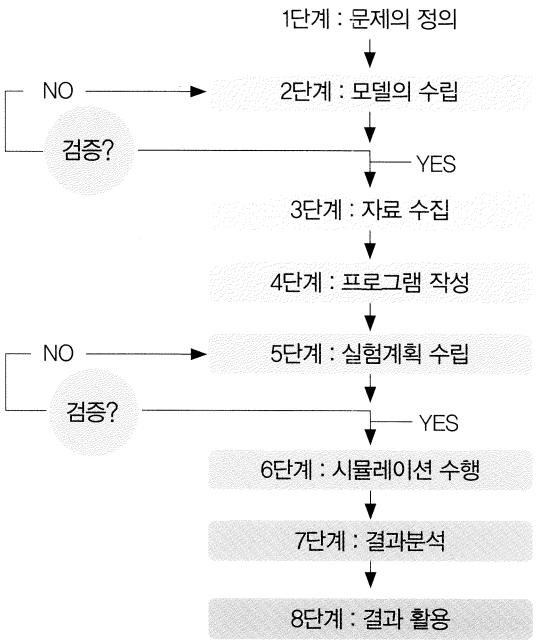



그림 9-7 **시뮬레이션의 일반적인 수행절차**

- **1단계 : 문제의 정의**(problem definition)

시뮬레이션의 첫 번째 단계인 문제 정의는 현실시스템의 목표와 연구목적이 되는 문제점을 명확히 파악하는 단계이다.

- **2단계 : 모델링**(model building)

문제가 명확히 파악되면 위에서 설명한 모델링 요소들을 바탕으로 모델을 수립한다. 이때 모델의 타당성에 대한 검증작업(validation)을 거쳐야 한다.

- **3단계 : 자료 수집**(data collection)

시뮬레이션에 투입될 자료(input data)를 수집해야 한다. 실제로 수집한 데이터 또는 참고 데이터들을 수집, 분석하여 실험의 상황과 조건을 실제와 가능한 일치하도록 해야 한다.

- **4단계 : 프로그램 작성**(coding)

모델이 수립되면 시뮬레이션이 작동하는 알고리즘을 프로그램으로 작성한다. 코딩(coding)이 완료되면 검증작업(verification)을 거쳐야 된다.

- 5단계 : 실험계획 수립(experimental design)

실험계획은 원하는 결과를 얻을 수 있도록 실험의 전략을 수립하는 것이다. 주어진 실험 상황과 조건에서 충분한 정보를 얻을 수 있게, 초기화의 시간, 전체 시뮬레이션의 시간, 반복의 횟수 등을 결정해야 한다.

- 6단계 : 시뮬레이션 수행(simulation)

실험계획을 바탕으로 초기조건, 수행시간, 수행횟수, 성능지표 등의 값을 설정하고 프로그램을 작동하여 시뮬레이션을 수행한다.

- 7단계 : 결과분석(analysis)

시뮬레이션 수행 결과에 대한 통계적 분석을 통하여 시스템의 성능지표(performance measure)에 대한 정보를 수집한다.

- 8단계 : 결과 활용(implementation)

시뮬레이션 결과의 분석으로부터 얻은 전략적 · 실무적 지식을 현실시스템의 설계와 개선에 활용한다.

## 5. 예시

간단한 예로, 농산물 도매시장에 전국에서 농산물을 적재한 트럭들이 들어오고 나가는 상황을 생각해 보자. 현재 5개의 하역 도크(dock)를 운영하고 있는데, 종종 트럭들이 제때 하역을 못하고 기다리는 일들이 일어나고 있다. 따라서 실험의 목적은, 경제성 측면에서 도크의 수를 늘리는 것이 좋은지 아니면 그대로 두는 것이 좋은지를 판단하기 위한 정보를 얻는 데 있다.

이 문제는 뒤에서 우리가 자세히 다룰 대기이론(queuing theory)에 관한 것이다. 대기이론에서는 이 시스템에 평균 몇 대의 트럭이 줄을 서서 기다릴 것인지, 트럭이 들어와서 나갈 때까지 얼마나 오랜 시간이 걸리는지 등을 '수리적'으로 계산하는 공식이 제시되어 있다. 그 공식은 시스템이 오랫동안 운영되어 이른바 안정상태(steady state)에 도달할 때 나타나는 값을 보여준다. 하지만 여기서 우리가 알고 싶은 것은, 새벽 4시, 아침 9시, 오후 2시, 밤 10시 등에는 어떤 상태가 되는지, 나아가 봄, 여름, 가을, 겨울에는 어떤 차이가 있는지 등의 정보이다. 이런 값들은 대기이론으로부터 얻을 수 없는 '실험적' 정보이다.

위의 문제를 이산사건 시뮬레이션으로 수행하기 위해서는 어떻게 해야 할까? 먼저, 트럭이 도착하는 시간의 간격(interval)과 트럭이 짐을 하역하는 데 걸리는 시간이 어떤 확률분포를 따른다고 가정한 후, 그 확률분포에 맞추어 컴퓨터가 사건(event)들을 임의로(random) 일으키게 한다. 즉, 2분만에 트럭이 도착하고 3분만에 하역을 마치고 나가고, 또 3분 후에 새 트럭이 도착하고 6분만에 나가고 하는 식의 사건을 계속 발생시키는 것이다. 시계가 계속 돌아가고 있는 상황에서 이 실험을 계속 반복하면, 어느 시간대에 이 시스템이 어떤 상태(state)에 있는지, 전 시간대와 비교하여 지금은 어떤 변화가 나타났는지 등을 알 수 있다. 또 언제 트럭이 길게 줄을 서서 기다리고, 언제 한가하게 도크가 비어 있는지도 알 수 있다. 또 계절별 차이도 알아볼 수 있다.

이러한 실험결과가 수집되면 궁극적으로는 경제성 분석을 수행한다. 도크를 늘릴 때 발생하는 투자 및 운용비용과 트럭들이 기다리면서 발생하는 지체 비용을 비교하여 어떤 결정을 하는 것이 더 경제적인지를 사전에 예측할 수 있는 것이다. 아니면 도크를 추가로 설치한 후, 바쁜 시간대에는 모든 도크를 운영하고 한가한 시간대에는 일부만 운영하는 방안도 검토할 수 있다.